Instituto Politécnico de Viana do Castelo

LICENCIATURA EM ENGENHARIA INFORMÁTICA

OPÇÃO II – APRENDIZAGEM ORGANIZACIONAL / SISTEMAS DE SUPORTE À DECISÃO

~ Data Science – Pré-processamento e criação de Modelos de Inteligência Artificial usando a framework MLFlow



29447 – Ivo Ramoa

ivoramoa@ipvc.pt

Jorge Ribeiro

- jribeiro@estg.ipvc.pt

Índice

1. Introdução
2. Objetivos
3. Ferramentas Utilizadas
4. Arquitetura do projeto e Dataset
5. Metodologia
6. Implementação do MLflow
7. Dashboard Interativo
8. Resultados e Discussão
9. Conclusão
10. Referências

Introdução

Este trabalho tem como objetivo **aplicar técnicas de aprendizagem automática a um dataset relacionado com indicadores de serviço, com o propósito de prever o valor de um indicador KPI.** Para isso, foi desenvolvido um processo que **inclui preparação dos dados, treino de modelos, avaliação de desempenho e visualização dos resultados.**

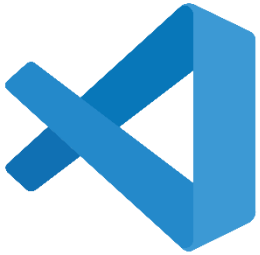
Foram implementados vários modelos de regressão e utilizada a plataforma MLflow para registo experimental. Além disso, foi criada uma aplicação interativa em Streamlit para explorar os resultados, analisar os modelos e testar novas previsões.

Objetivos

Os objetivos deste trabalho são:

- **Preparar e transformar o dataset** fornecido.
- **Implementar diferentes modelos de regressão** para prever o indicador KPI.
- **Comparar o desempenho dos modelos** com métricas adequadas.
- **Utilizar o MLflow para registar experiências,** parâmetros e resultados.
- **Desenvolver um dashboard interativo** para visualizar os dados e os modelos.
- **Criar um formulário** para introdução de novos dados e geração de previsões.

Ferramentas Utilizadas



VsCode: Ambiente de desenvolvimento utilizado para escrever, organizar e executar o código do projeto. Permitiu gerir os ficheiros, correr scripts Python e integrar o controlo de versões com Git.



Python: Linguagem de programação utilizada para todo o desenvolvimento do projeto, incluindo tratamento de dados, treino de modelos e integração com as ferramentas utilizadas.

Ferramentas Utilizadas

MLflow: Plataforma utilizada para registar experiências de treino, incluindo parâmetros, métricas e modelos gerados. Permitiu acompanhar, comparar e organizar de forma estruturada as diferentes execuções realizadas no projeto.

Scikit-learn: Biblioteca de aprendizagem automática usada para implementar e avaliar os modelos de regressão. Foi também utilizada para pré-processamento dos dados e cálculo das métricas de desempenho.

Ferramentas Utilizadas



Streamlit: Framework utilizada para desenvolver o dashboard interativo do projeto. Permitiu criar uma aplicação com várias páginas para visualizar resultados, comparar modelos, analisar erros e gerar novas previsões.

Arquitetura do projeto e Dataset



O projeto foi organizado de **forma modular, separando claramente os dados, os modelos, os outputs, as páginas da aplicação e o código fonte.** Esta estrutura facilita o desenvolvimento, a manutenção, a execução do treino e a visualização dos resultados.

Arquitetura do projeto e Dataset


```
id_registo,data_registo,unidade_organizacional,tipo_servico,indicador_si,taxa_resolucao,tempo_resposta,satisfacao_cidadao,volume_interacoes,canal_utilizado,taxa_abandono,er
1,2024-04-12,Direcção De Serviços Financeiros,Telefone,83.02,87.37,36,3.8,368,Presencial,22.41,7,Sim,Processo Complicado,Empresa,Cultura,63.13
2,2024-12-14,Departamento De Inovação E Digitalização,Balcão Único,75.53,89.71,29,4.1,349,Email,14.87,1,Sim,Bom Serviço,Funcionário Público,Saúde,63.58
3,2024-09-27,Direcção De Recursos Humanos,Chatbot,85.73,75.96,38,3.3,398,Telefone,15.42,5,Não,Processo Complicado,Estudante,Inovação,73.64
4,2024-04-16,Departamento De Planeamento Estratégico,Email,78.33,73.82,57,3.4,74,Aplicacao_Movel,15.32,11,Sim,Processo Complicado,Funcionário Público,Digitalização,99.19
```

Foi utilizado o ficheiro **Dataset-iGov.csv,** contendo variáveis numéricas, categóricas e temporais relacionadas com indicadores de serviço. A **variável alvo definida para previsão foi o indicador_kpi,** permitindo formular o problema como uma tarefa de regressão.

Fonte: Ficheiro disponibilizado pelo docente no Moodle.

Arquitetura do projeto e Dataset

```python
def prepare_dataset(df: pd.DataFrame) -> pd.DataFrame:
    df = df.copy()

    df[DATE_COLUMN] = pd.to_datetime(df[DATE_COLUMN], errors="coerce")
    if df[DATE_COLUMN].isna().any():
        raise ValueError("Existem datas inválidas em 'data_registo'.")

    df["ano"] = df[DATE_COLUMN].dt.year
    df["mes"] = df[DATE_COLUMN].dt.month
    df["dia"] = df[DATE_COLUMN].dt.day
    df["trimestre"] = df[DATE_COLUMN].dt.quarter
    df["dia_semana"] = df[DATE_COLUMN].dt.dayofweek

    return df


def split_features_target(prepared_df: pd.DataFrame):
    x = prepared_df.drop(
        columns=[TARGET_COLUMN, DATE_COLUMN, *DROP_COLUMNS],
        errors="ignore"
    )
    y = prepared_df[TARGET_COLUMN].copy()
    return x, y
```

Foi realizado o **pré-processamento inicial dos dados,** incluindo a conversão da variável de data e a **criação de novas variáveis temporais,** como o ano, mês, dia, trimestre e dia da semana. Em seguida, os **dados foram divididos entre variáveis preditoras e variável alvo,** excluindo colunas não relevantes para o modelo.

Arquitetura do projeto e Dataset

```python
def build_preprocessor(numeric_cols, categorical_cols):
    numeric_pipeline = Pipeline(
        steps=[
            ("imputer", SimpleImputer(strategy="median")),
            ("scaler", StandardScaler())
        ]
    )

    categorical_pipeline = Pipeline(
        steps=[
            ("imputer", SimpleImputer(strategy="most_frequent")),
            ("onehot", OneHotEncoder(handle_unknown="ignore", sparse_output=False))
        ]
    )

    preprocessor = ColumnTransformer(
        transformers=[
            ("num", numeric_pipeline, numeric_cols),
            ("cat", categorical_pipeline, categorical_cols)
        ],
        remainder="drop"
    )

    return preprocessor
```

Foi criado um **pipeline de pré-processamento que aplica imputação, normalização nas variáveis numéricas e codificação one-hot nas variáveis categóricas.** O processo foi organizado com ColumnTransformer, garantindo preparação consistente dos dados para todos os modelos.

Metodologia

```
Treino concluído com sucesso.
Dataset preparado: C:\Uni\3º ano\2ºSemestre\AO\TP1-D2\tp1-
Métricas holdout dos modelos: C:\Uni\3º ano\2ºSemestre\AO\
Métricas de validação cruzada: C:\Uni\3º ano\2ºSemestre\AO
Predições de teste: C:\Uni\3º ano\2ºSemestre\AO\TP1-D2\tp1
Importância das variáveis: C:\Uni\3º ano\2ºSemestre\AO\TP1
Melhor modelo guardado em: C:\Uni\3º ano\2ºSemestre\AO\TP1
Modelo da Árvore de Decisão guardado em: C:\Uni\3º ano\2ºS
Melhor modelo identificado: Dummy Regressor
Modelo usado para importância das variáveis: Random Forest
```

Nesta imagem o **treino foi executado com sucesso,** o que gera automaticamente os principais ficheiros do projeto: **dataset preparado, métricas holdout, métricas de validação cruzada, predições, importância das variáveis e modelos guardados.**

O processo identifica ainda o melhor modelo e guarda também a Árvore de Decisão para uma análise posterior.

Metodologia

```python
def main():
    ensure_directories()

    if not RAW_DATASET_PATH.exists():
        raise FileNotFoundError(
            f"Dataset não encontrado em: {RAW_DATASET_PATH}\n"
            "Coloca o ficheiro Dataset-iGov.csv dentro de data/raw/.'
        )

    raw_df = load_dataset(RAW_DATASET_PATH)
    prepared_df = prepare_dataset(raw_df)
    prepared_df.to_csv(PREPARED_DATASET_PATH, index=False)

    x, y = split_features_target(prepared_df)
    numeric_cols, categorical_cols = get_feature_groups(x)

    x_train, x_test, y_train, y_test = train_test_split(
        x,
        y,
        test_size=TEST_SIZE,
        random_state=RANDOM_STATE
    )
```

O dataset bruto é carregado, preparado e transformado antes do treino dos modelos. Depois disso, os **dados são divididos entre variáveis preditoras e variável alvo.**

Em seguida, é feita **a separação entre colunas numéricas e categóricas e aplica-se a divisão treino/teste para avaliação do desempenho.**

Metodologia

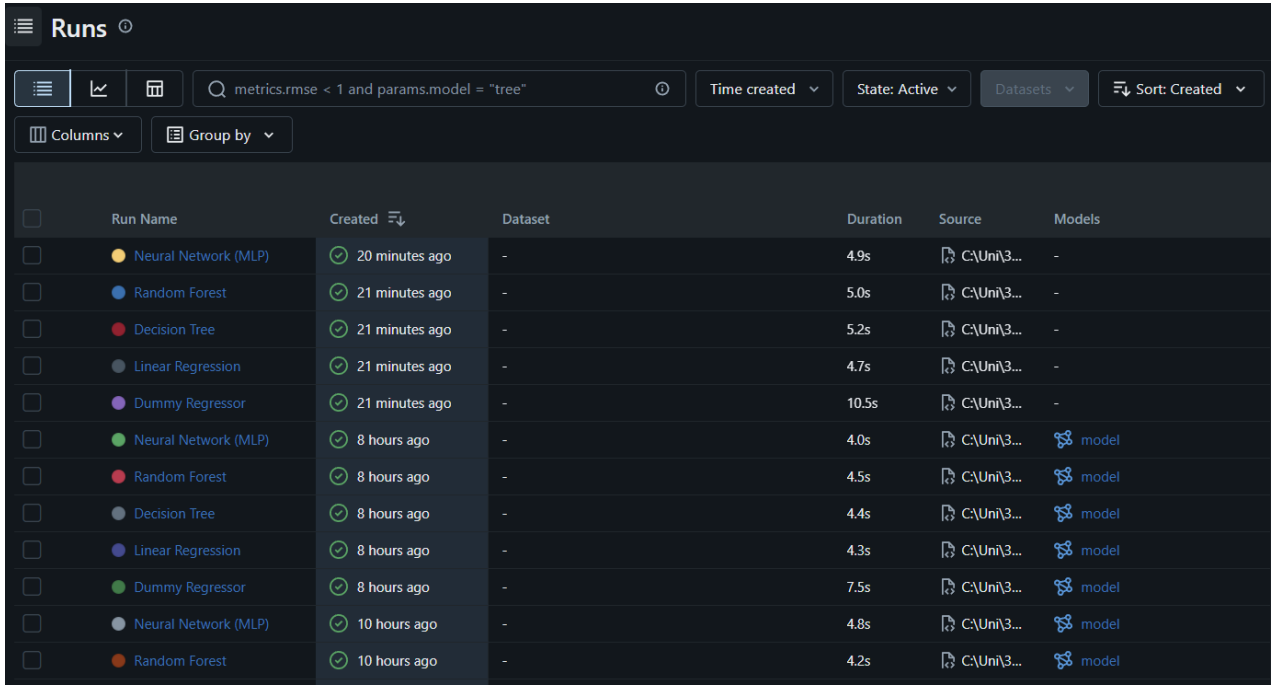
```
scoring = {
    "MAE": "neg_mean_absolute_error",
    "RMSE": "neg_root_mean_squared_error",
    "R2": "r2"
}

cv = KFold(
    n_splits=CROSS_VALIDATION_FOLDS,
    shuffle=True,
    random_state=RANDOM_STATE
)
```

Os modelos foram avaliados com as métricas **MAE**, **RMSE** e **R²**, permitindo medir erro médio, penalização de erros grandes e capacidade explicativa.

Além disso, foi usada **validação cruzada K-Fold**, tornando a comparação entre modelos mais robusta e fiável.

Implementação do MLflow

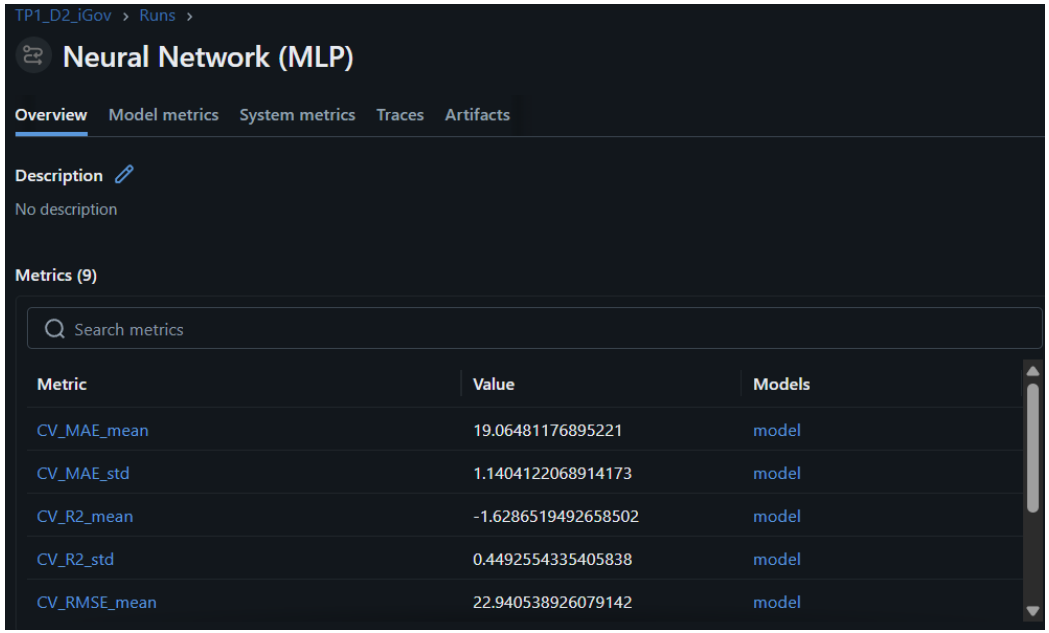


Run Name	Created	Dataset	Duration	Source	Models
Neural Network (MLP)	20 minutes ago	-	4.9s	C:\Uni\3...	-
Random Forest	21 minutes ago	-	5.0s	C:\Uni\3...	-
Decision Tree	21 minutes ago	-	5.2s	C:\Uni\3...	-
Linear Regression	21 minutes ago	-	4.7s	C:\Uni\3...	-
Dummy Regressor	21 minutes ago	-	10.5s	C:\Uni\3...	-
Neural Network (MLP)	8 hours ago	-	4.0s	C:\Uni\3...	model
Random Forest	8 hours ago	-	4.5s	C:\Uni\3...	model
Decision Tree	8 hours ago	-	4.4s	C:\Uni\3...	model
Linear Regression	8 hours ago	-	4.3s	C:\Uni\3...	model
Dummy Regressor	8 hours ago	-	7.5s	C:\Uni\3...	model
Neural Network (MLP)	10 hours ago	-	4.8s	C:\Uni\3...	model
Random Forest	10 hours ago	-	4.2s	C:\Uni\3...	model

O MLflow foi utilizado para **registar todas as experiências realizadas ao longo do trabalho,** em que cada modelo treinado gerou uma run própria, permitindo organizar de forma clara os resultados e acompanhar diferentes execuções ao longo do tempo.

Assim, foi possível **comparar os diferentes modelos como Dummy Regressor ou Regressão Linear, mantendo um histórico estruturado das experiências.**

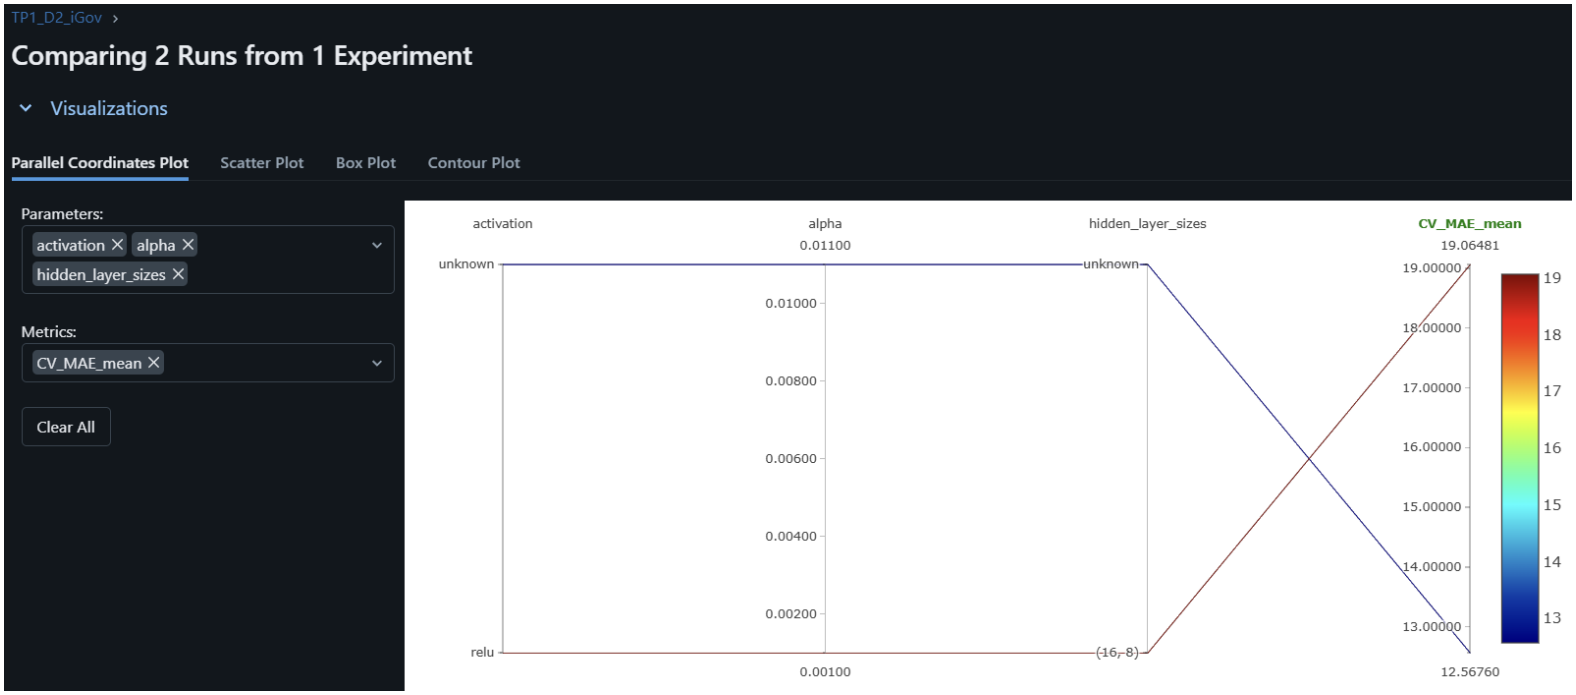
Implementação do MLflow



Ao abrir uma run específica no MLflow, é possível **consultar as métricas registadas para esse modelo,** incluindo resultados de validação cruzada e métricas globais de desempenho, o que permite centralizar num único local os valores relevantes de avaliação e apoiar a análise individual de cada abordagem implementada.

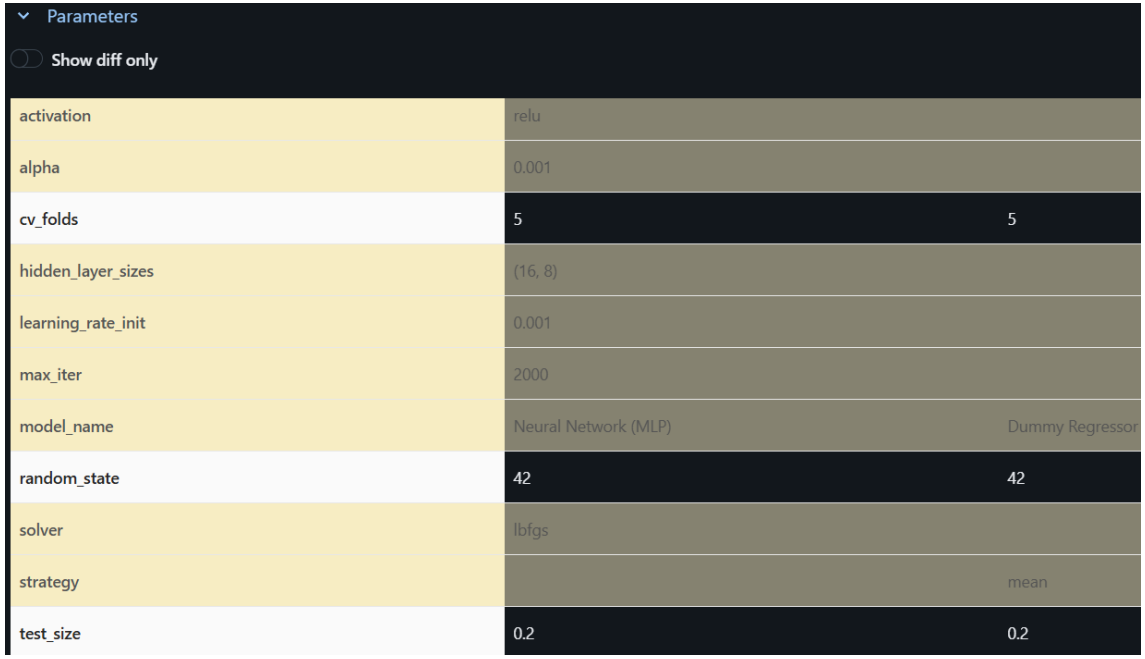
Implementação do MLflow

Pré-processamento e criação de Modelos de Inteligência Artificial usando a framework MLFlow.



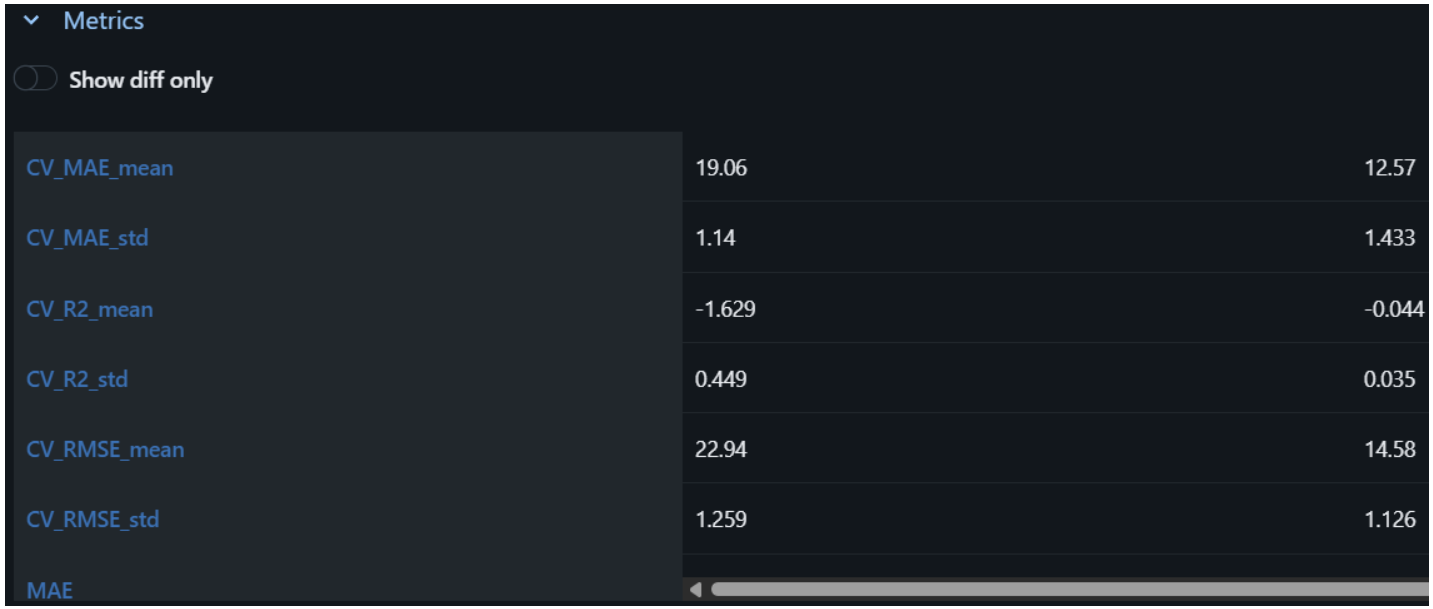
Esta visualização mostra a **comparação entre duas runs do mesmo experimento no MLflow,** recorrendo a um **gráfico de coordenadas paralelas.** A análise permite relacionar parâmetros da rede neuronal, como a ativação, o valor de *alpha* e a estrutura das camadas escondidas, com a métrica **CV_MAE_mean**.

Implementação do MLflow



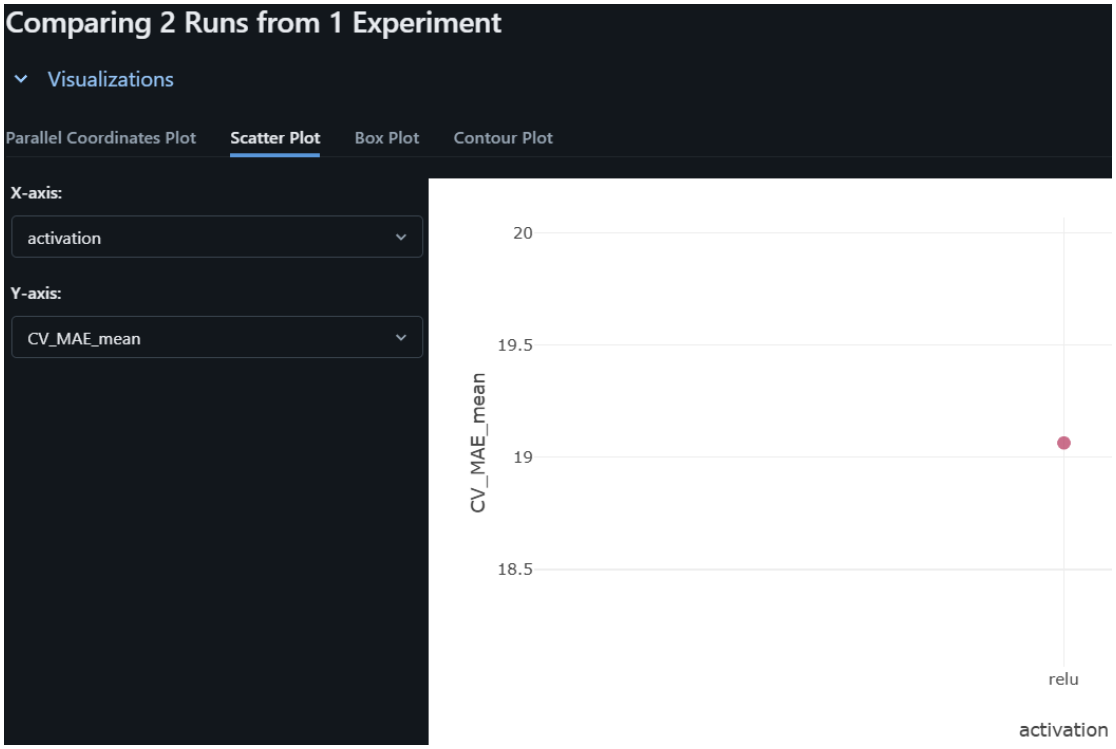
Nesta vista são apresentados, lado a lado, os **parâmetros registados em duas runs distintas.** A **comparação permite identificar rapidamente quais os valores que diferem entre modelos,** como o tipo de modelo, a estratégia utilizada ou os hiperparâmetros específicos da rede neuronal.

Implementação do MLflow



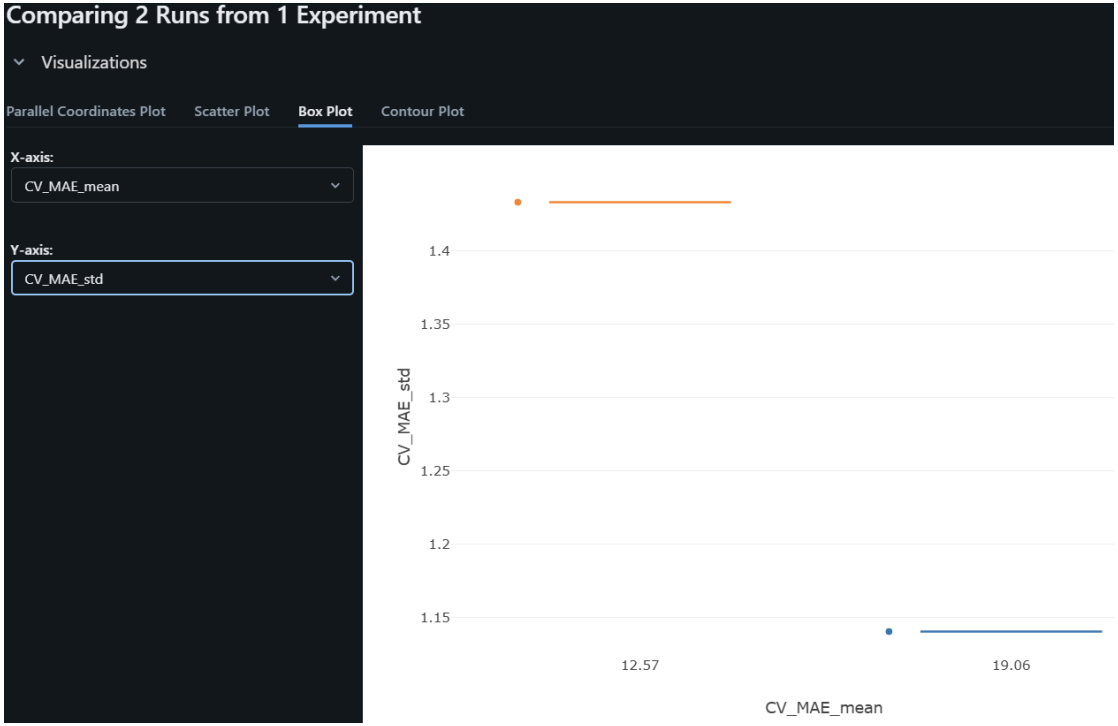
Aqui são comparadas diretamente as métricas registadas nas duas execuções selecionadas, incluindo medidas de validação cruzada como **CV_MAE_mean**, **CV_RMSE_mean** e **CV_R2_mean**. Esta vista permite analisar de forma objetiva qual das runs apresenta melhor comportamento estatístico.

Implementação do MLflow



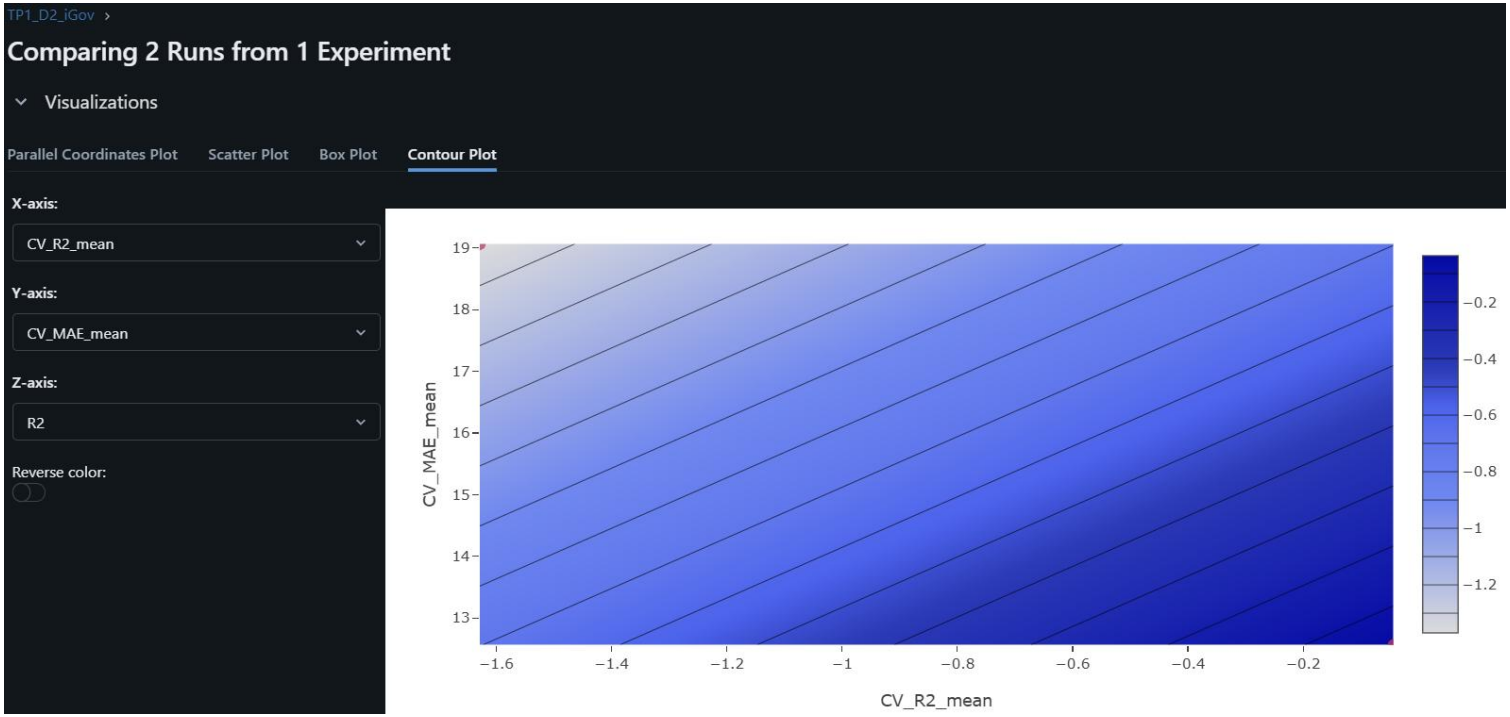
O **gráfico de dispersão permite representar a relação entre um parâmetro selecionado e uma métrica de desempenho.** Neste caso, observa-se a ligação entre a função de ativação e o valor médio do erro absoluto em validação cruzada.

Implementação do MLflow



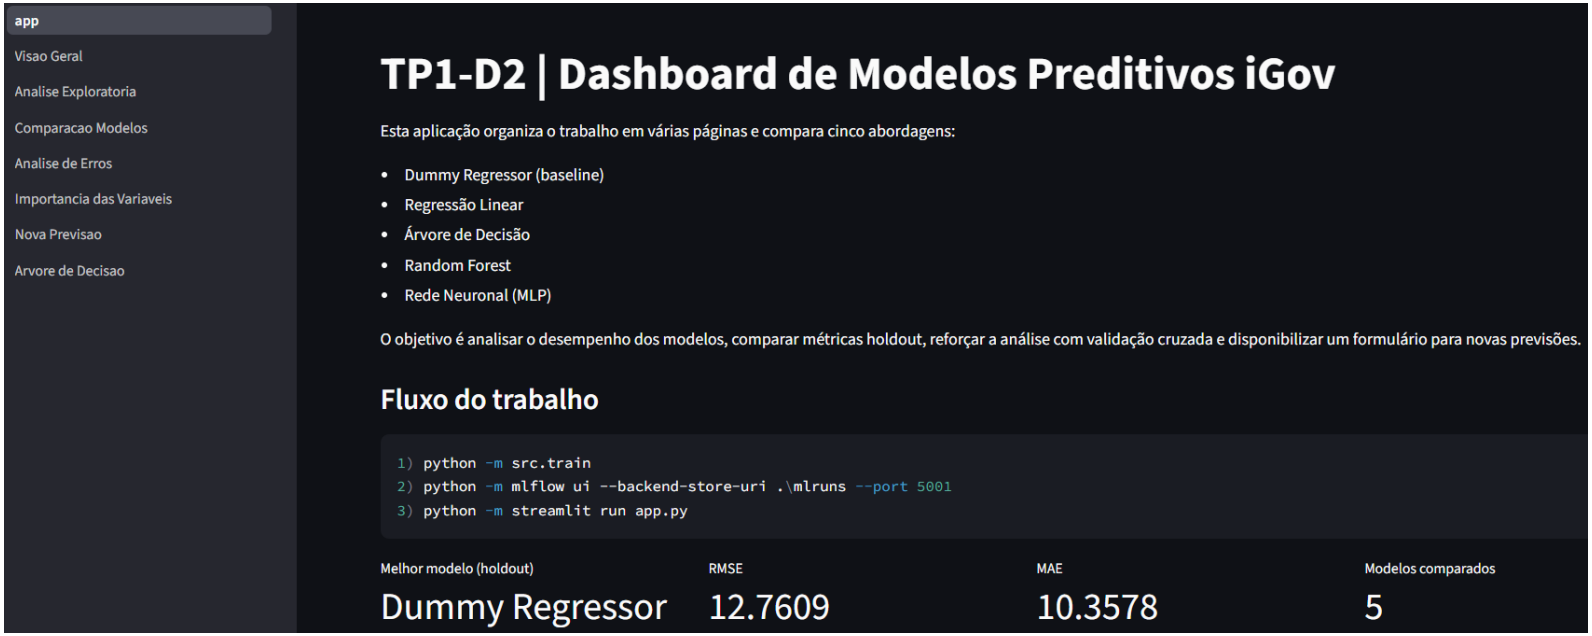
O box plot permite **comparar simultaneamente uma métrica principal com a sua dispersão,** ajudando a interpretar o desempenho médio e a estabilidade dos resultados. Neste exemplo, observa-se a relação entre **CV_MAE_mean** e **CV_MAE_std** nas runs comparadas.

Implementação do MLflow



O contour plot representa a **relação entre várias métricas em simultâneo,** permitindo observar como diferentes combinações de desempenho distribuem-se no espaço de análise. Neste caso, são relacionadas métricas como **CV_R2_mean**, **CV_MAE_mean** e **R2**.

Dashboard Interativo



A aplicação foi desenvolvida em Streamlit e organizada em várias páginas, permitindo **analisar e comparar diferentes modelos de regressão** de forma estruturada. São considerados cinco modelos: **Dummy Regressor, Regressão Linear, Árvore de Decisão, Random Forest e Rede Neuronal (MLP).**

Dashboard Interativo

Resumo holdout

	run_id	model	MAE	RMSE	R2
0	0e5a4c519ff9418e9aecc7c59216fa2b	Dummy Regressor	10.3578	12.7609	-0.0358
1	69944727b91c4ed58605a19c6c97afd3	Random Forest	10.9047	12.8872	-0.0564
2	f4d3fe4170af4ce1ae07a5e270a0f0b1	Linear Regression	10.9257	14.5997	-0.3558
3	3516079403bf4c0e8af88ee8c8382e8a	Decision Tree	12.9675	16.7178	-0.7778
4	2e054eb758a74d81b1114c6389872b82	Neural Network (MLP)	15.4922	19.2999	-1.3693

Melhor modelo (CV)
Dummy Regressor

CV RMSE médio
14.5824

CV R^2 médio
-0.0438

Resumo de validação cruzada

	model	CV_MAE_mean	CV_MAE_std	CV_RMSE_mean	CV_RMSE_std	CV_R2_mean	CV_R2_std
0	Dummy Regressor	12.5676	1.4332	14.5824	1.1262	-0.0438	0.0351
1	Random Forest	13.1045	1.2595	15.2397	0.9482	-0.1426	0.0398
2	Decision Tree	14.9736	1.363	17.9343	1.7126	-0.6108	0.3804
3	Linear Regression	15.8057	1.9372	19.11	2.0898	-0.8164	0.3567
4	Neural Network (MLP)	19.0648	1.1404	22.9405	1.2586	-1.6287	0.4493

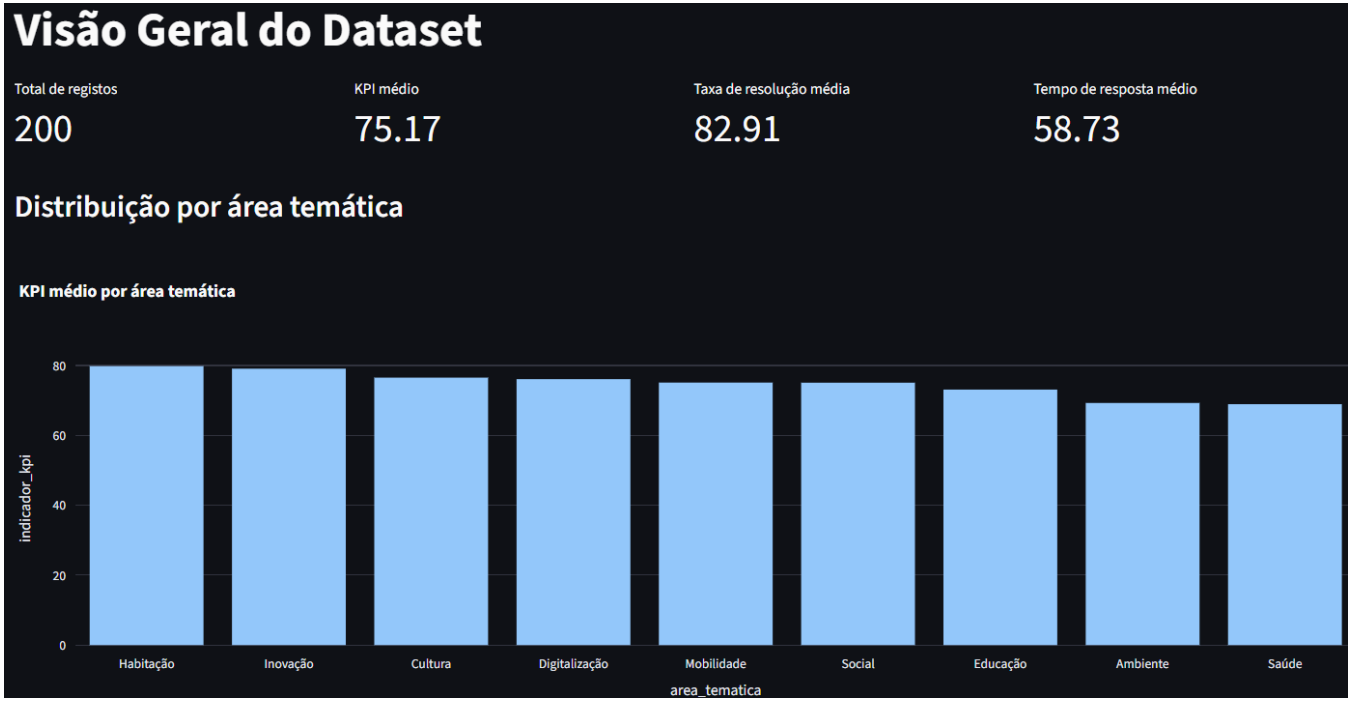
Nesta secção são apresentados os **resultados obtidos pelos diferentes modelos,** tanto em holdout como em validação cruzada. A tabela de holdout permite comparar diretamente métricas como MAE, RMSE e R^2 para cada modelo.

Dashboard Interativo



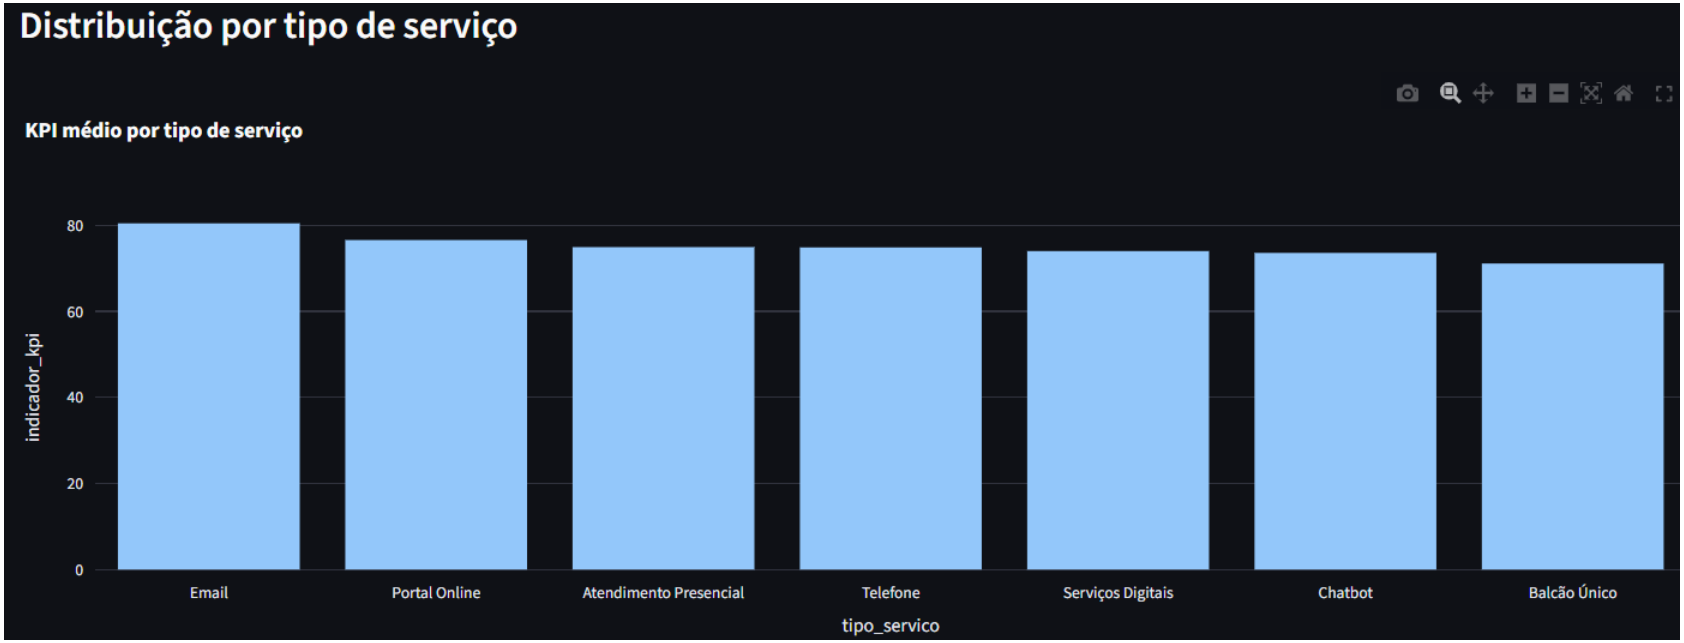
A aplicação inclui uma **leitura geral dos resultados,** destacando o **papel do Dummy Regressor como baseline e a importância da validação cruzada na comparação entre modelos.** O critério principal de seleção do melhor modelo baseia-se no menor valor de RMSE.

Dashboard Interativo



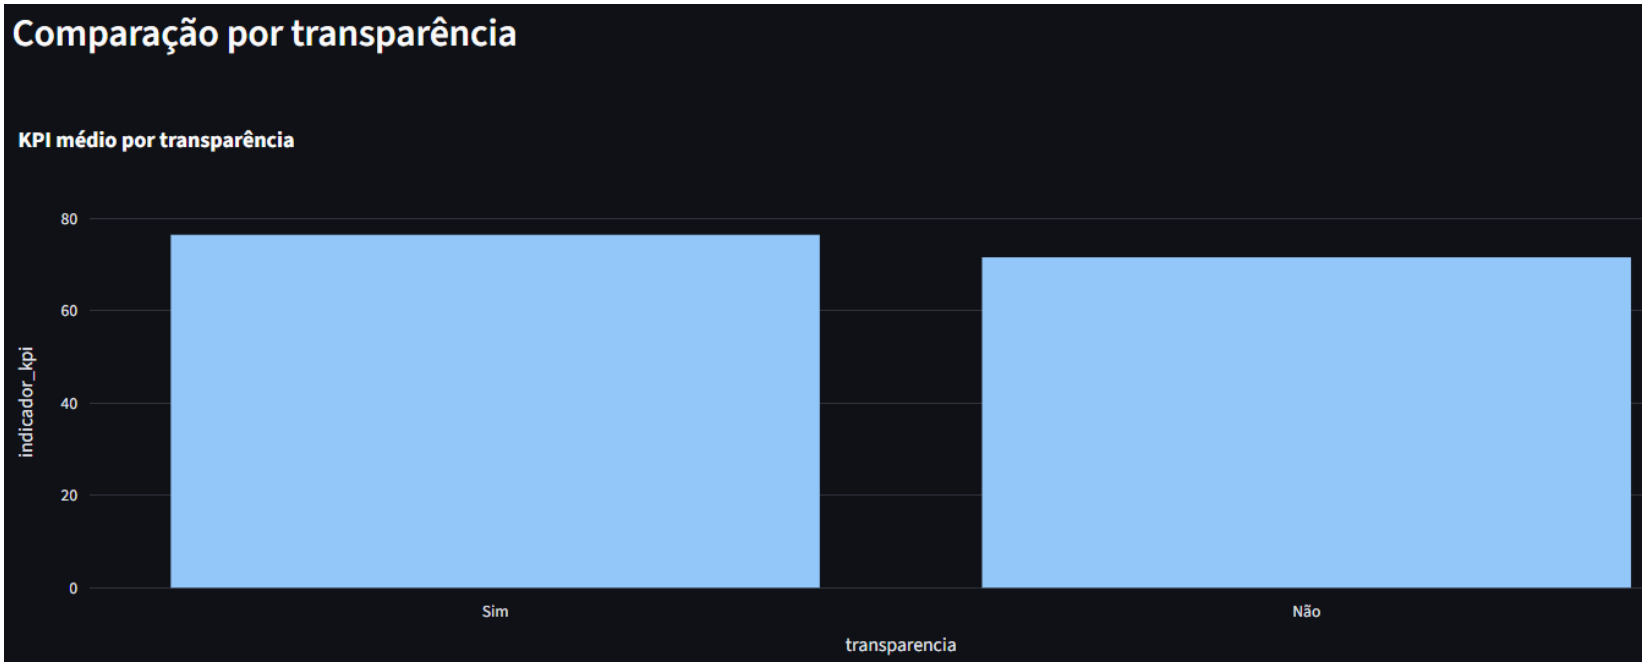
A página **Visão Geral apresenta uma síntese inicial do dataset,** destacando o número total de registos e alguns indicadores médios relevantes, como o KPI, a taxa de resolução e o tempo de resposta. Estes valores permitem obter uma leitura rápida do contexto geral dos dados antes da modelação.

Dashboard Interativo



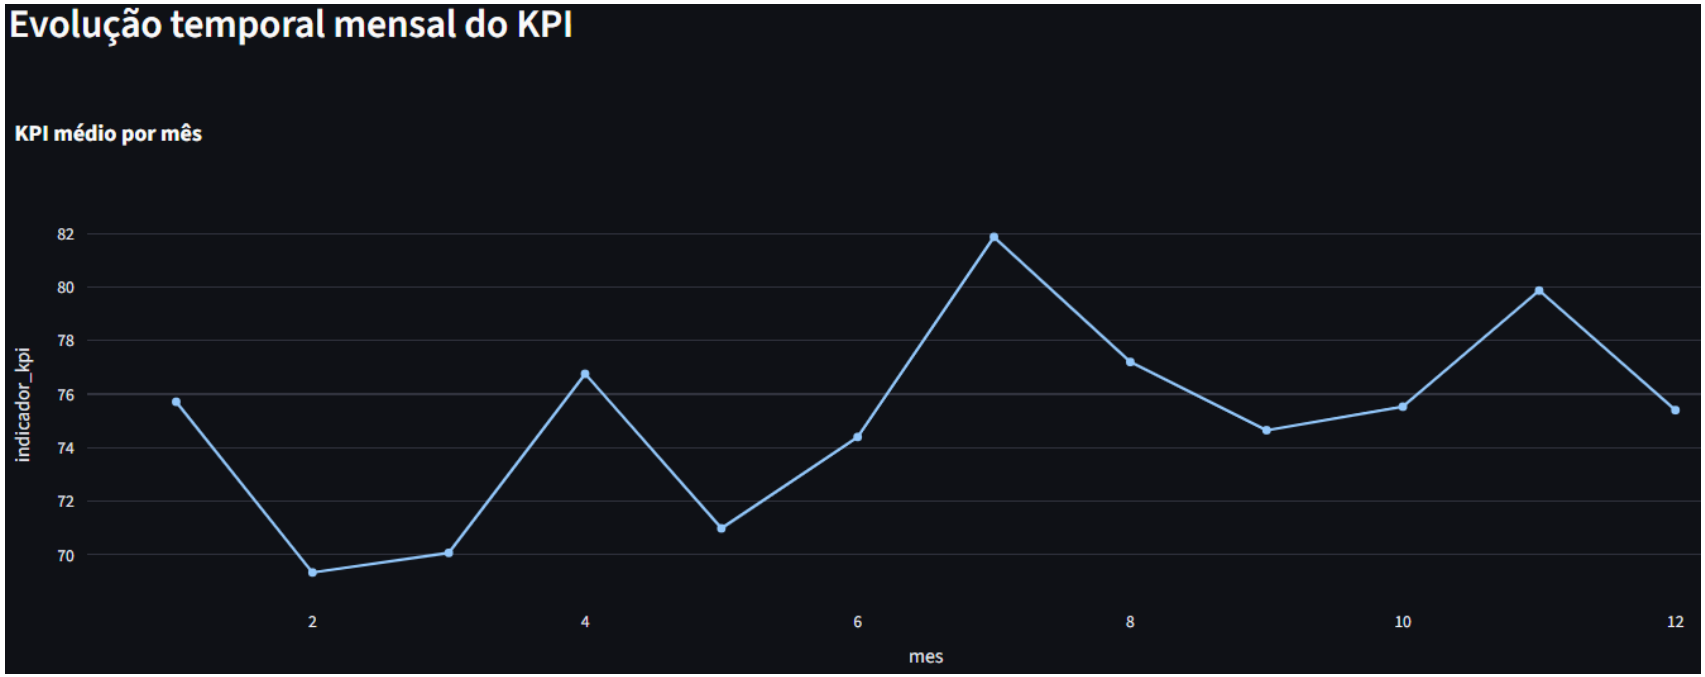
Neste gráfico é apresentada a **distribuição do KPI médio por tipo de serviço,** permitindo comparar o desempenho associado a diferentes formas de atendimento e interação. A visualização ajuda a identificar que alguns serviços apresentam valores médios de KPI superiores a outros.

Dashboard Interativo



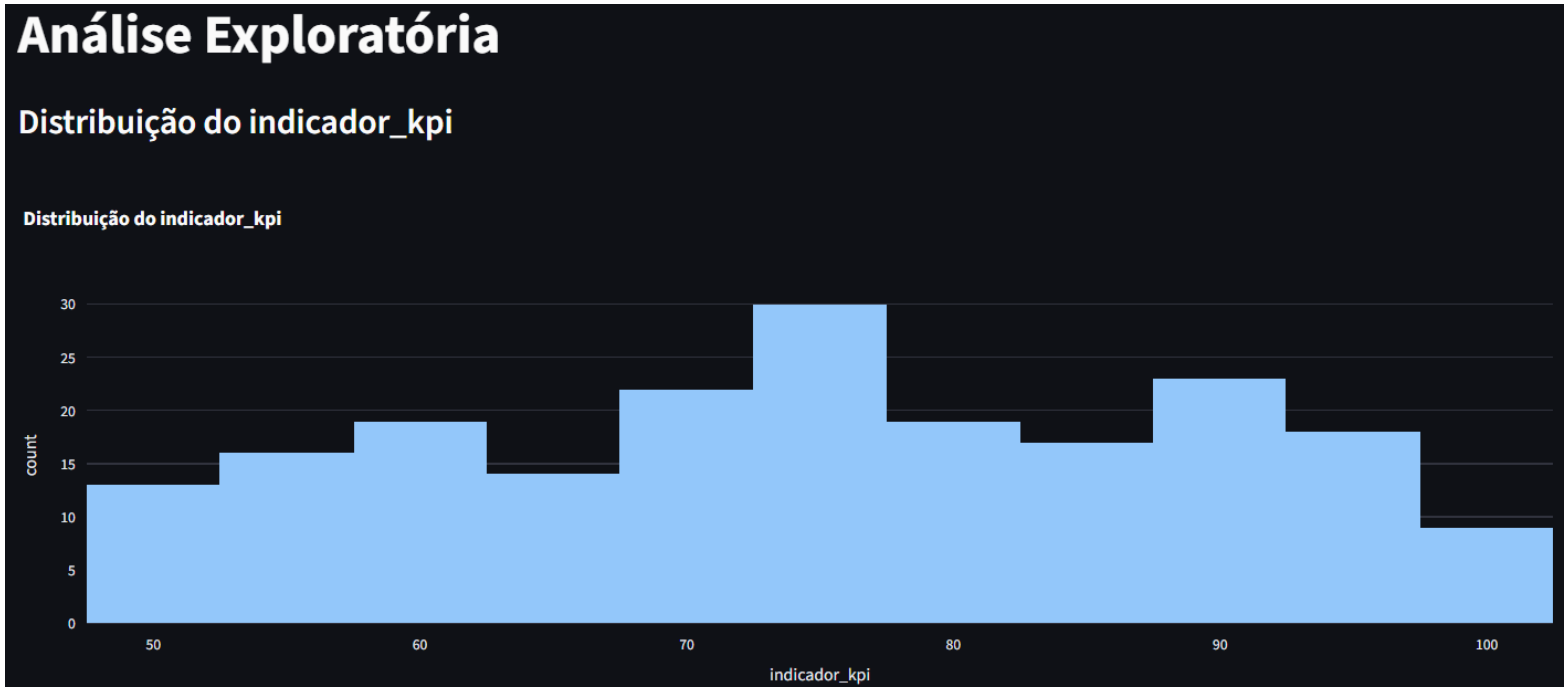
A comparação **por transparência mostra o KPI médio** para registos em que existe ou não transparência associada. Esta visualização permite observar diferenças agregadas entre os dois grupos e perceber se esta variável pode estar relacionada com o nível médio do indicador KPI.

Dashboard Interativo



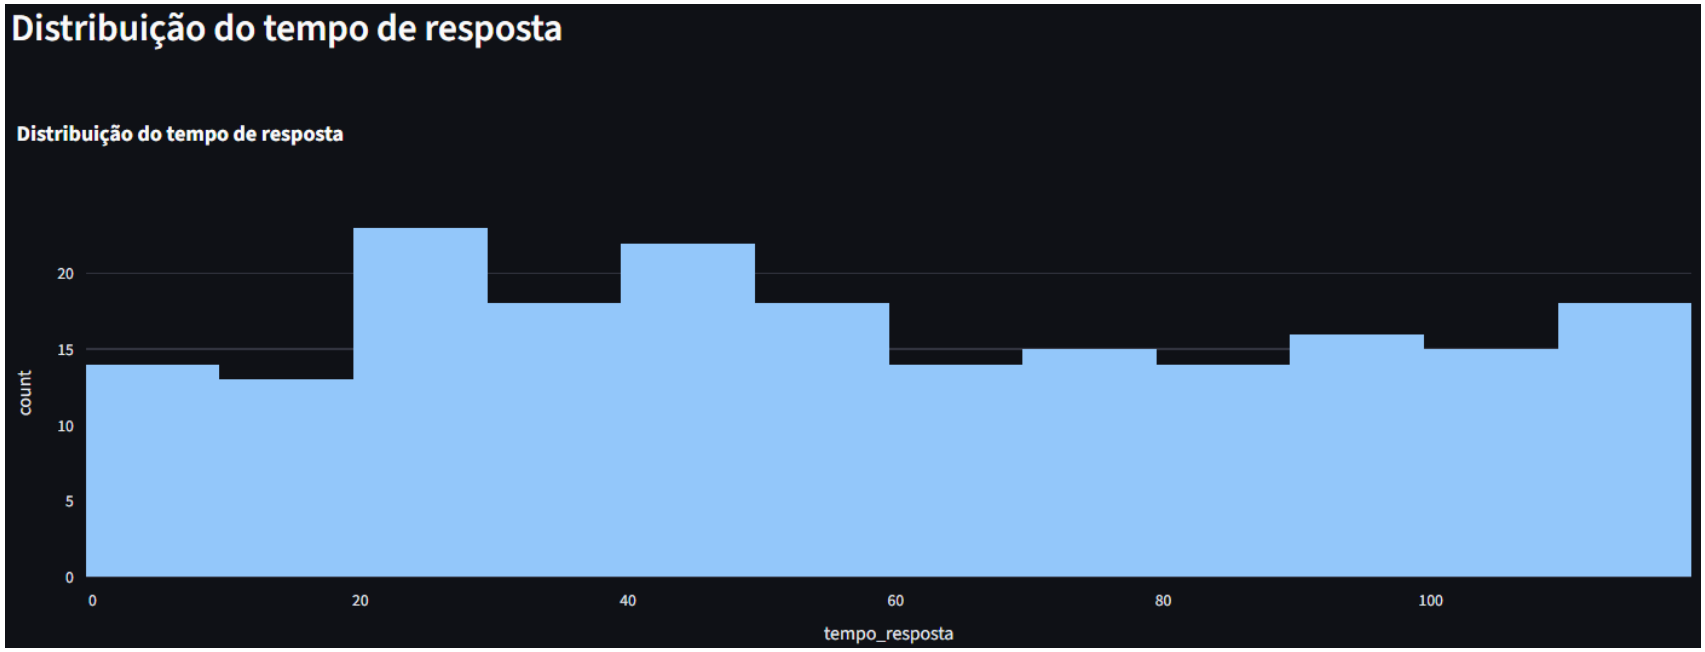
Este gráfico representa a **evolução temporal do KPI médio ao longo dos meses,** permitindo observar oscilações no comportamento do indicador ao longo do período analisado. A componente temporal é importante porque ajuda a perceber se existem tendências, subidas ou quebras em momentos específicos.

Dashboard Interativo



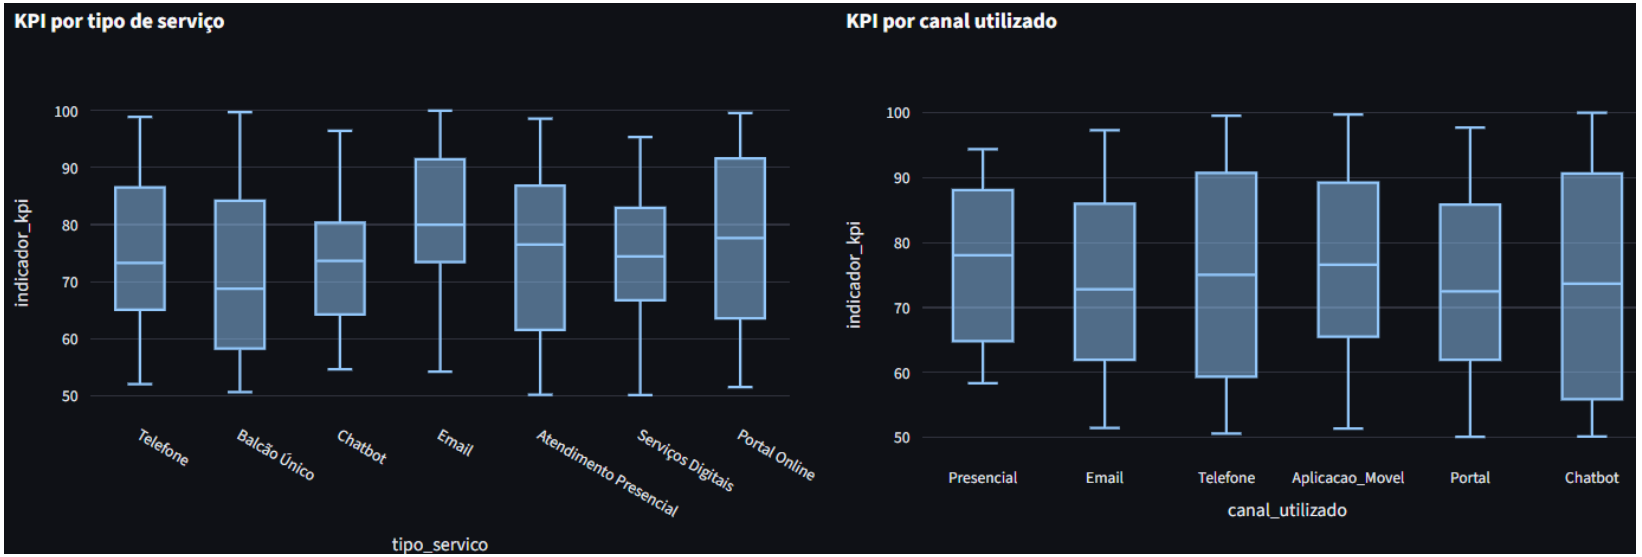
Este histograma mostra a **distribuição dos valores do indicador KPI ao longo do dataset.** Observa-se que os valores concentram-se maioritariamente entre intervalos intermédios, sem presença evidente de valores extremos isolados.

Dashboard Interativo



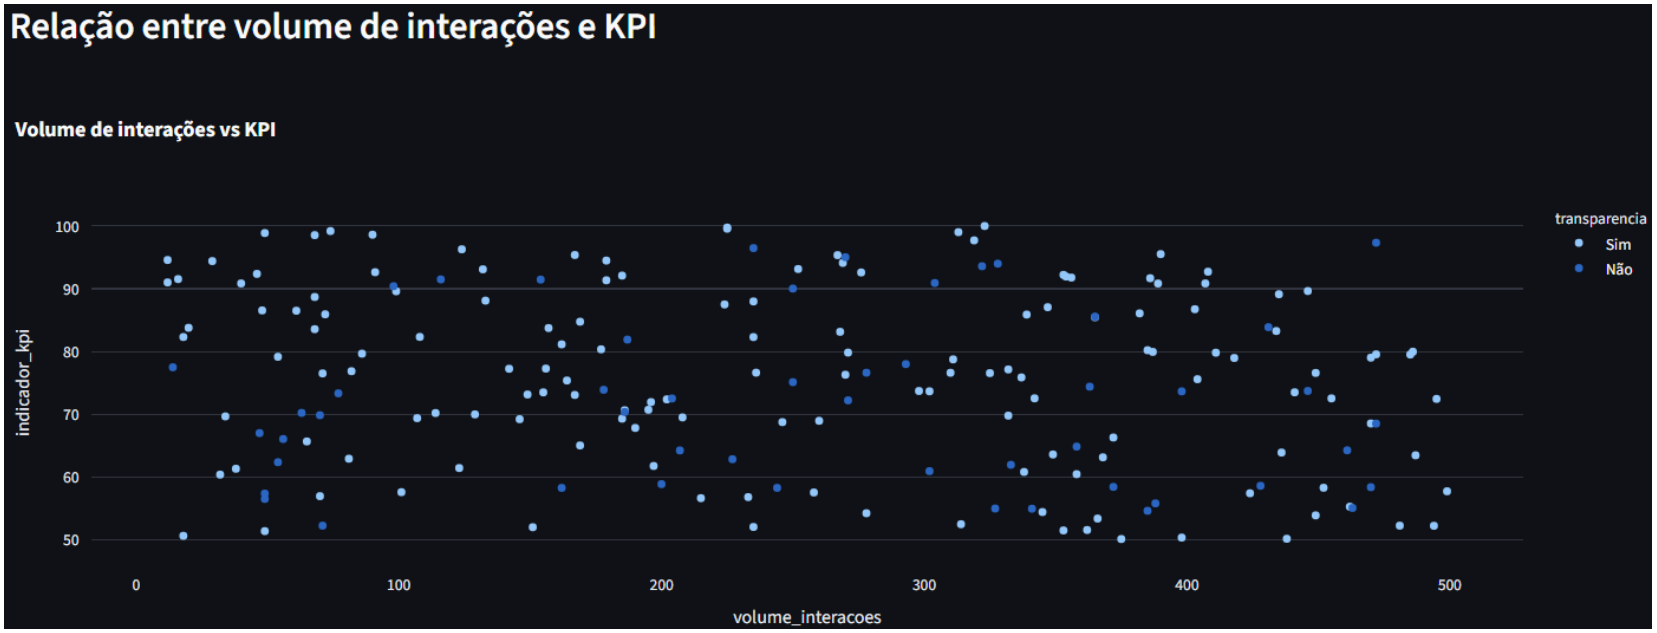
O gráfico apresenta a **distribuição do tempo de resposta,** evidenciando uma dispersão significativa dos valores ao longo de vários intervalos. Isto indica que existem serviços com tempos bastante distintos.

Dashboard Interativo



Os boxplots mostram a **distribuição do KPI por tipo de serviço e por canal utilizado,** permitindo analisar medianas, dispersão e possíveis outliers. Observam-se diferenças entre categorias, indicando que o contexto de atendimento pode influenciar o desempenho do KPI.

Dashboard Interativo



O scatter plot representa a **relação entre o volume de interações e o KPI**, incluindo distinção por transparência. Não se observa uma relação linear clara entre as variáveis, sugerindo que o impacto do volume no KPI pode ser mais complexo.

Dashboard Interativo

Resumo estatístico

	count	mean	std	min	25%	50%	75%	max
indicador_si	200	81.5833	12.3734	60.43	71.3925	82.39	92.5575	99.99
taxa_resolucao	200	82.9099	7.7699	70.41	75.84	82.275	88.7925	97.72
tempo_resposta	200	58.73	33.9911	1	29.75	54.5	88.25	118
satisfacao_cidadao	200	3.9855	0.5911	3	3.5	4	4.5	5
volume_interacoes	200	251.59	142.1268	12	131.25	251	366.5	499
taxa_abandono	200	12.5555	6.5684	0.23	7.8975	13.325	16.595	24.83
erros_tecnicos	200	7.035	4.1762	0	3	7	11	14
indicador_kpi	200	75.1668	14.2108	50.11	63.075	75.475	87.61	99.99

A tabela apresenta **estatísticas descritivas das principais variáveis,** incluindo média, desvio padrão, mínimos e máximos. Estes valores permitem compreender a escala, dispersão e comportamento geral dos dados.

Dashboard Interativo

Comparação de Modelos

Melhor modelo segundo holdout RMSE: Dummy Regressor

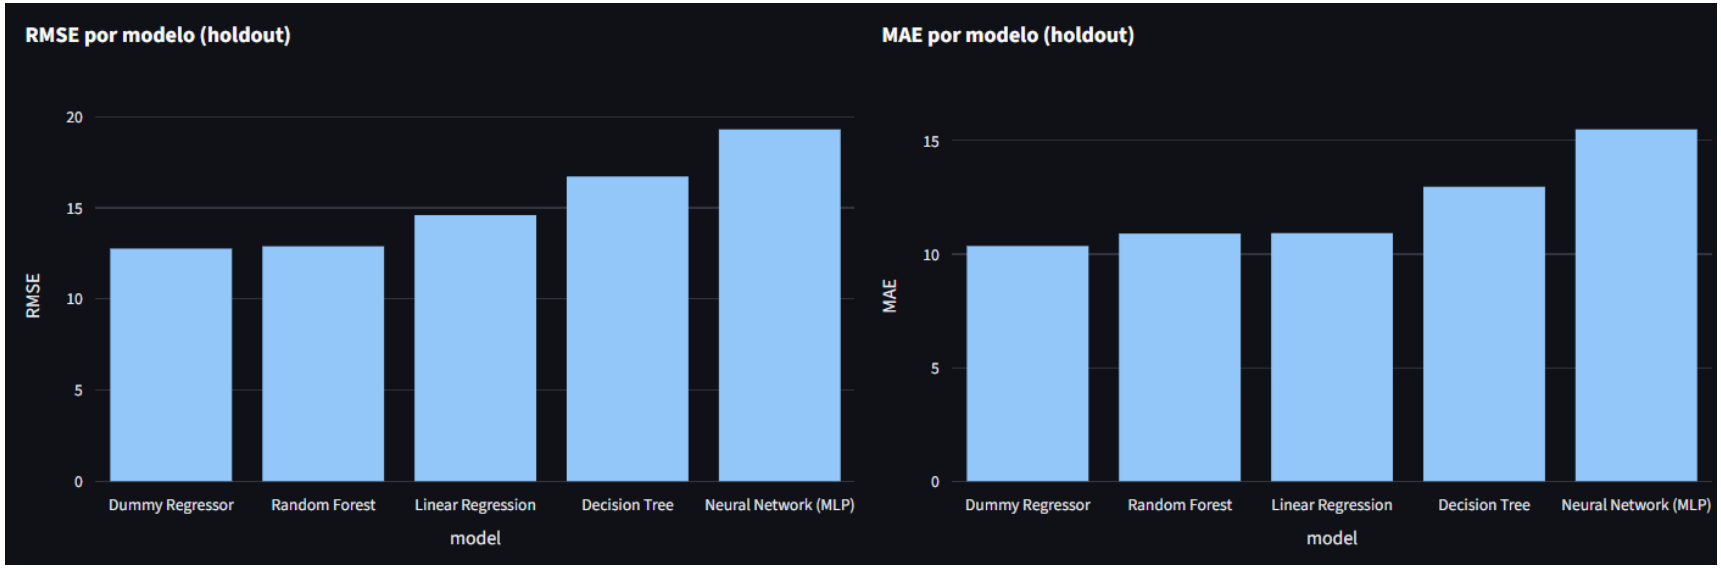
Melhor modelo segundo CV RMSE médio: Dummy Regressor

Métricas holdout

	run_id	model	MAE	RMSE	R2
0	0e5a4c519ff9418e9aecc7c59216fa2b	Dummy Regressor	10.3578	12.7609	-0.0358
1	69944727b91c4ed58605a19c6c97afd3	Random Forest	10.9047	12.8872	-0.0564
2	f4d3fe4170af4ce1ae07a5e270a0f0b1	Linear Regression	10.9257	14.5997	-0.3558
3	3516079403bf4c0e8af88ee8c8382e8a	Decision Tree	12.9675	16.7178	-0.7778
4	2e054eb758a74d81b1114c6389872b82	Neural Network (MLP)	15.4922	19.2999	-1.3693

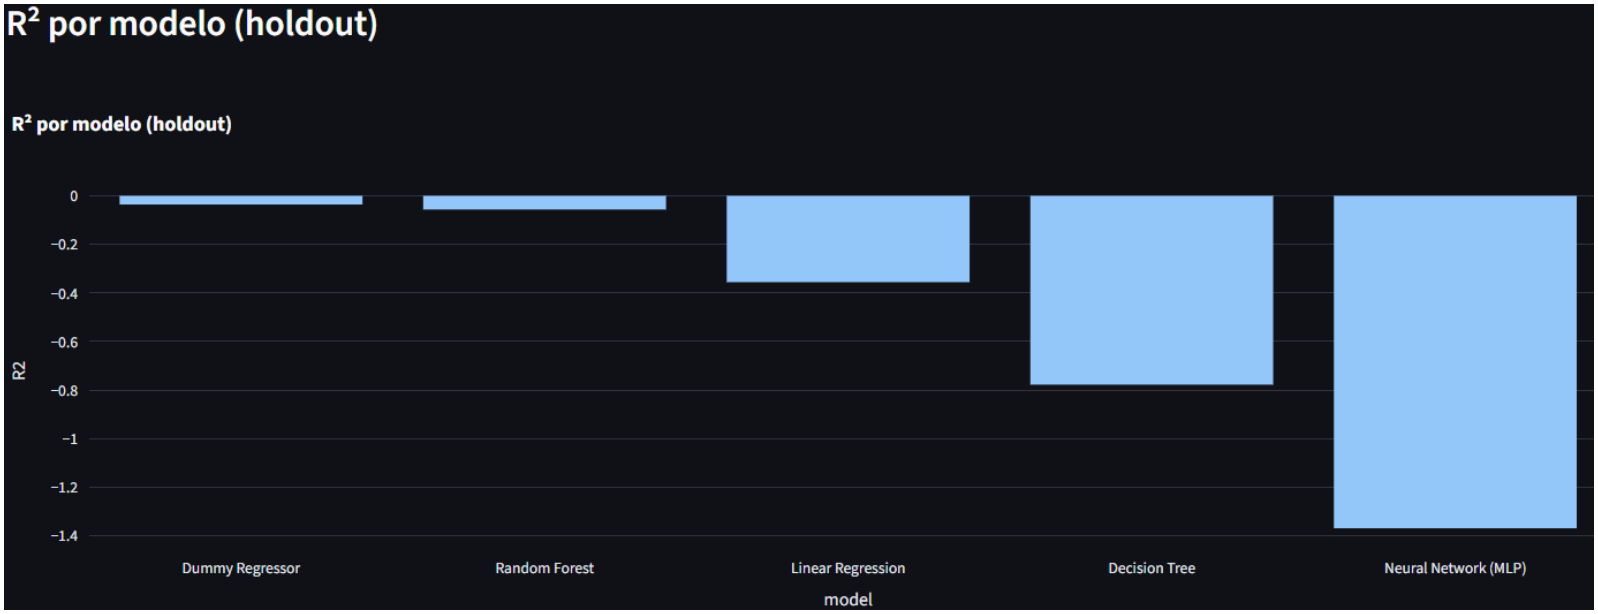
Nesta secção são apresentados os resultados obtidos em **holdout**, isto é, numa divisão fixa entre treino e teste. A tabela permite comparar diretamente os cinco modelos com base nas métricas **MAE**, **RMSE** e **R²**. Nesta avaliação, o **Dummy Regressor** surge com o menor RMSE, funcionando como melhor baseline neste dataset.

Dashboard Interativo



Os gráficos de barras facilitam a comparação visual entre os modelos segundo duas métricas de erro: **RMSE** e **MAE**. O RMSE penaliza mais fortemente erros elevados, enquanto o MAE representa o erro absoluto médio de forma mais direta.

Dashboard Interativo

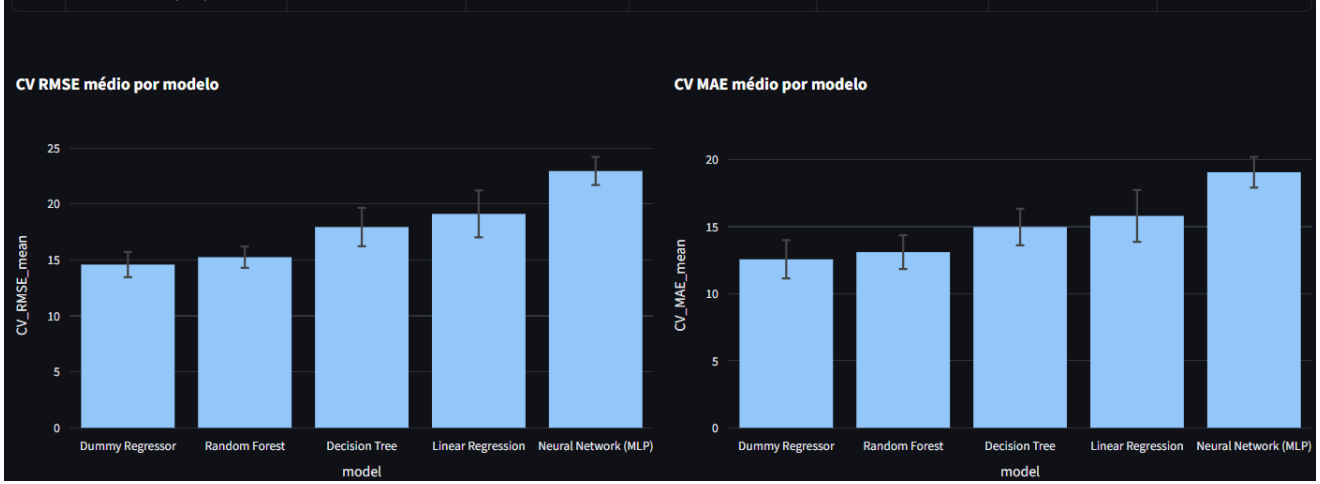


O gráfico de **R²** mostra a capacidade explicativa de cada modelo relativamente aos dados observados. Neste caso, todos os valores são negativos, o que indica que nenhum dos modelos conseguiu explicar o problema de forma satisfatória nesta avaliação.

Dashboard Interativo

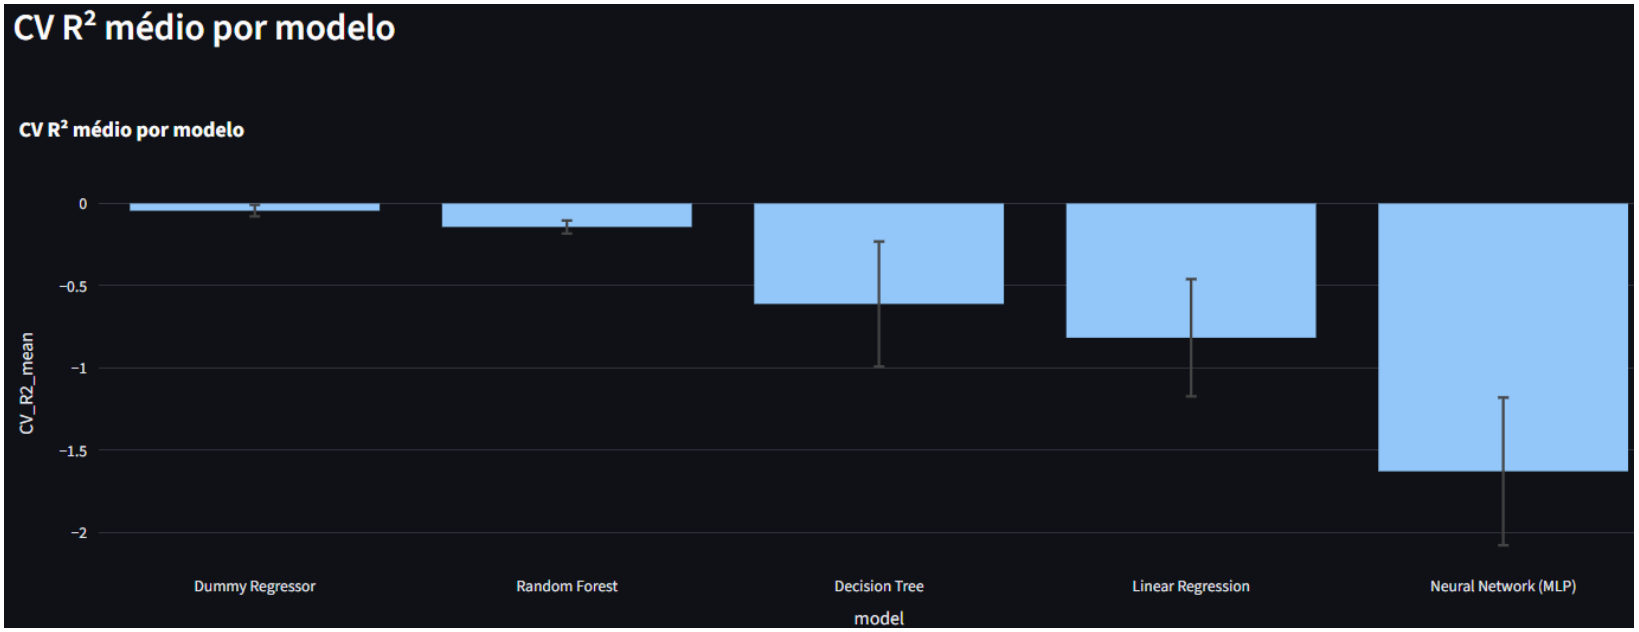
Métricas de validação cruzada (5 folds)

	model	CV_MAE_mean	CV_MAE_std	CV_RMSE_mean	CV_RMSE_std	CV_R2_mean	CV_R2_std
0	Dummy Regressor	12.5676	1.4332	14.5824	1.1262	-0.0438	0.0351
1	Random Forest	13.1045	1.2595	15.2397	0.9482	-0.1426	0.0398
2	Decision Tree	14.9736	1.363	17.9343	1.7126	-0.6108	0.3804
3	Linear Regression	15.8057	1.9372	19.11	2.0898	-0.8164	0.3567
4	Neural Network (MLP)	19.0648	1.1404	22.9405	1.2586	-1.6287	0.4493



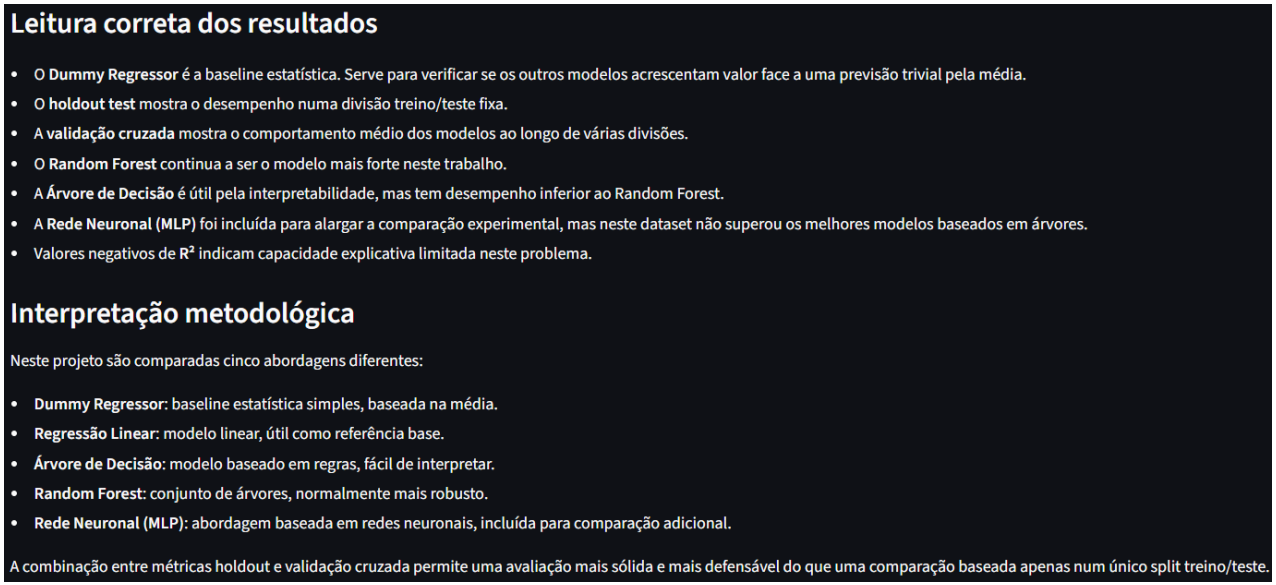
A validação cruzada com **5 folds** reforça a robustez da análise, permitindo observar o comportamento médio dos modelos ao longo de várias divisões dos dados. Para além dos valores médios, são também apresentados os desvios padrão, que ajudam a interpretar a estabilidade dos resultados.

Dashboard Interativo



Este gráfico mostra o valor médio de **R²** em validação cruzada, juntamente com a respetiva variabilidade. Tal como no holdout, os valores mantêm-se negativos, o que confirma que a capacidade explicativa dos modelos é reduzida neste problema.

Dashboard Interativo



Leitura correta dos resultados

- O **Dummy Regressor** é a baseline estatística. Serve para verificar se os outros modelos acrescentam valor face a uma previsão trivial pela média.
- O **holdout test** mostra o desempenho numa divisão treino/teste fixa.
- A **validação cruzada** mostra o comportamento médio dos modelos ao longo de várias divisões.
- O **Random Forest** continua a ser o modelo mais forte neste trabalho.
- A **Árvore de Decisão** é útil pela interpretabilidade, mas tem desempenho inferior ao Random Forest.
- A **Rede Neuronal (MLP)** foi incluída para alargar a comparação experimental, mas neste dataset não superou os melhores modelos baseados em árvores.
- Valores negativos de R^2 indicam capacidade explicativa limitada neste problema.

Interpretação metodológica

Neste projeto são comparadas cinco abordagens diferentes:

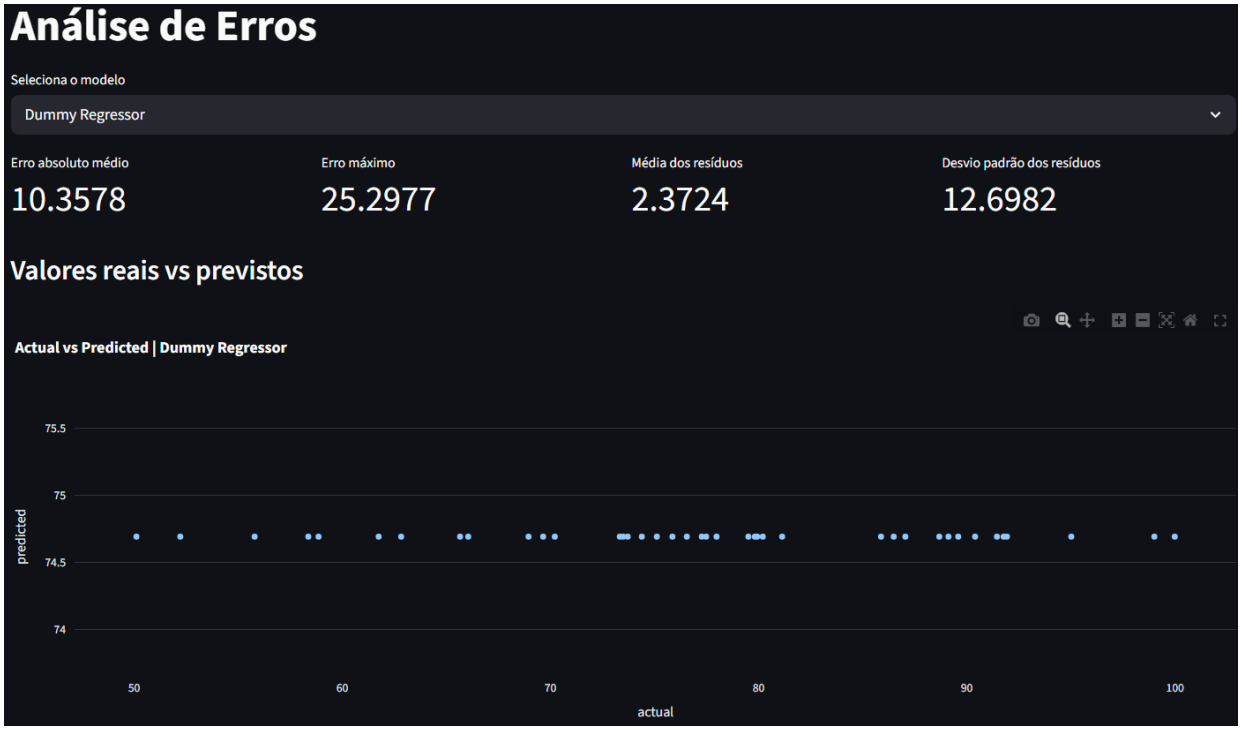
- **Dummy Regressor**: baseline estatística simples, baseada na média.
- **Regressão Linear**: modelo linear, útil como referência base.
- **Árvore de Decisão**: modelo baseado em regras, fácil de interpretar.
- **Random Forest**: conjunto de árvores, normalmente mais robusto.
- **Rede Neuronal (MLP)**: abordagem baseada em redes neuronais, incluída para comparação adicional.

A combinação entre métricas holdout e validação cruzada permite uma avaliação mais sólida e mais defensável do que uma comparação baseada apenas num único split treino/teste.

Esta secção resume a leitura correta das comparações realizadas. O **Dummy Regressor** é tratado como baseline estatística, permitindo perceber se os restantes modelos acrescentam valor real face a uma previsão trivial baseada na média.

A análise mostra que o **Random Forest** continua metodologicamente a ser o modelo mais forte entre os modelos preditivos mais elaborados, enquanto a **Árvore de Decisão** destaca-se pela interpretabilidade e a **Rede Neuronal (MLP)** não conseguiu superar os modelos baseados em árvores neste dataset.

Dashboard Interativo



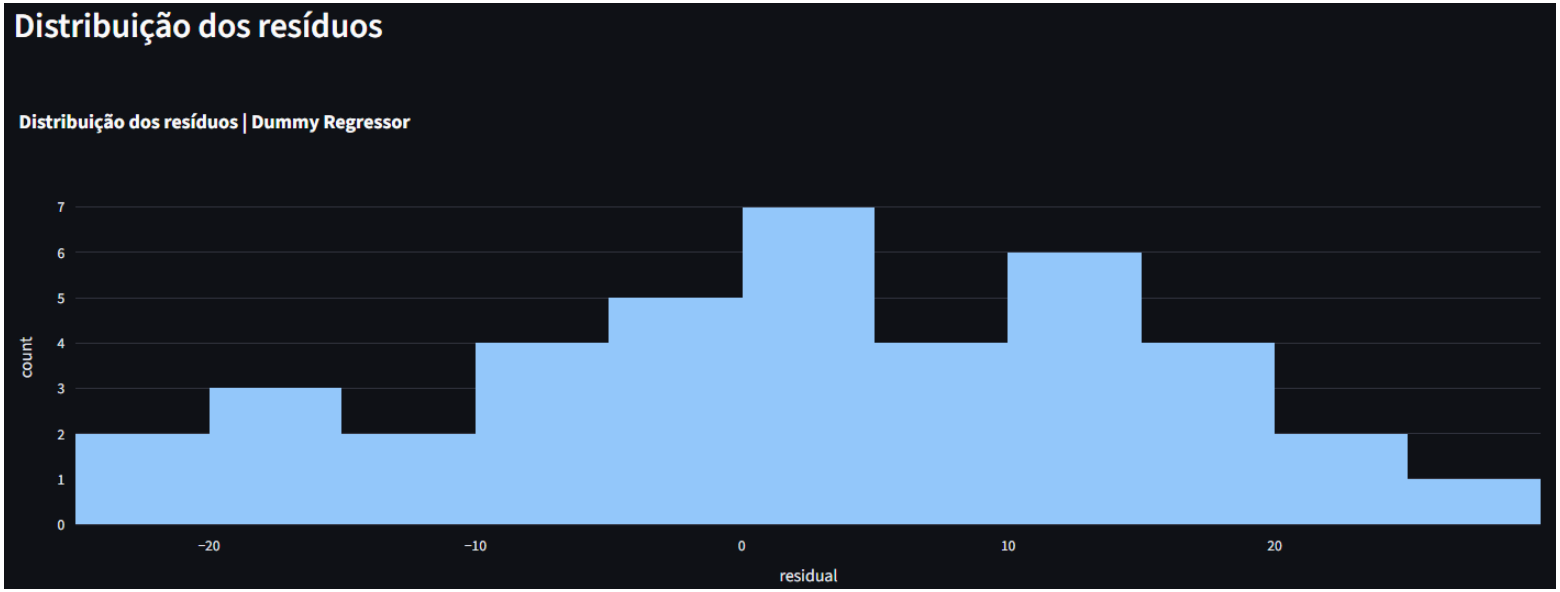
Esta página apresenta os **principais indicadores de erro para o modelo selecionado,** incluindo erro absoluto médio, erro máximo, média dos resíduos e desvio padrão dos resíduos. Estes valores permitem obter uma visão rápida do comportamento global do modelo nas previsões realizadas.

Dashboard Interativo



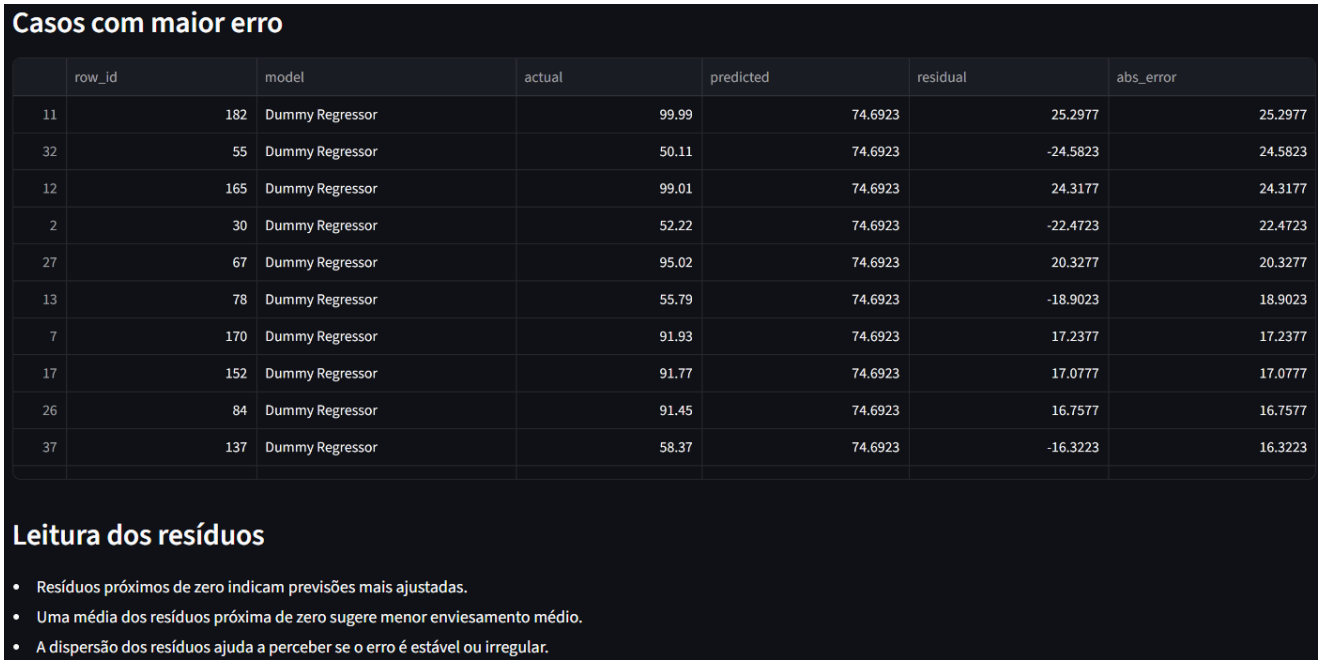
O gráfico compara os valores reais do KPI com os valores previstos pelo modelo. No caso do Dummy Regressor, todas as previsões coincidem num valor constante, o que resulta numa linha horizontal de previsão.

Dashboard Interativo



O gráfico de resíduos representa a **diferença entre o valor real e o valor previsto para cada observação.** Como o Dummy Regressor produz sempre a mesma previsão, todos os resíduos se distribuem verticalmente em torno desse único valor previsto.

Dashboard Interativo



Casos com maior erro

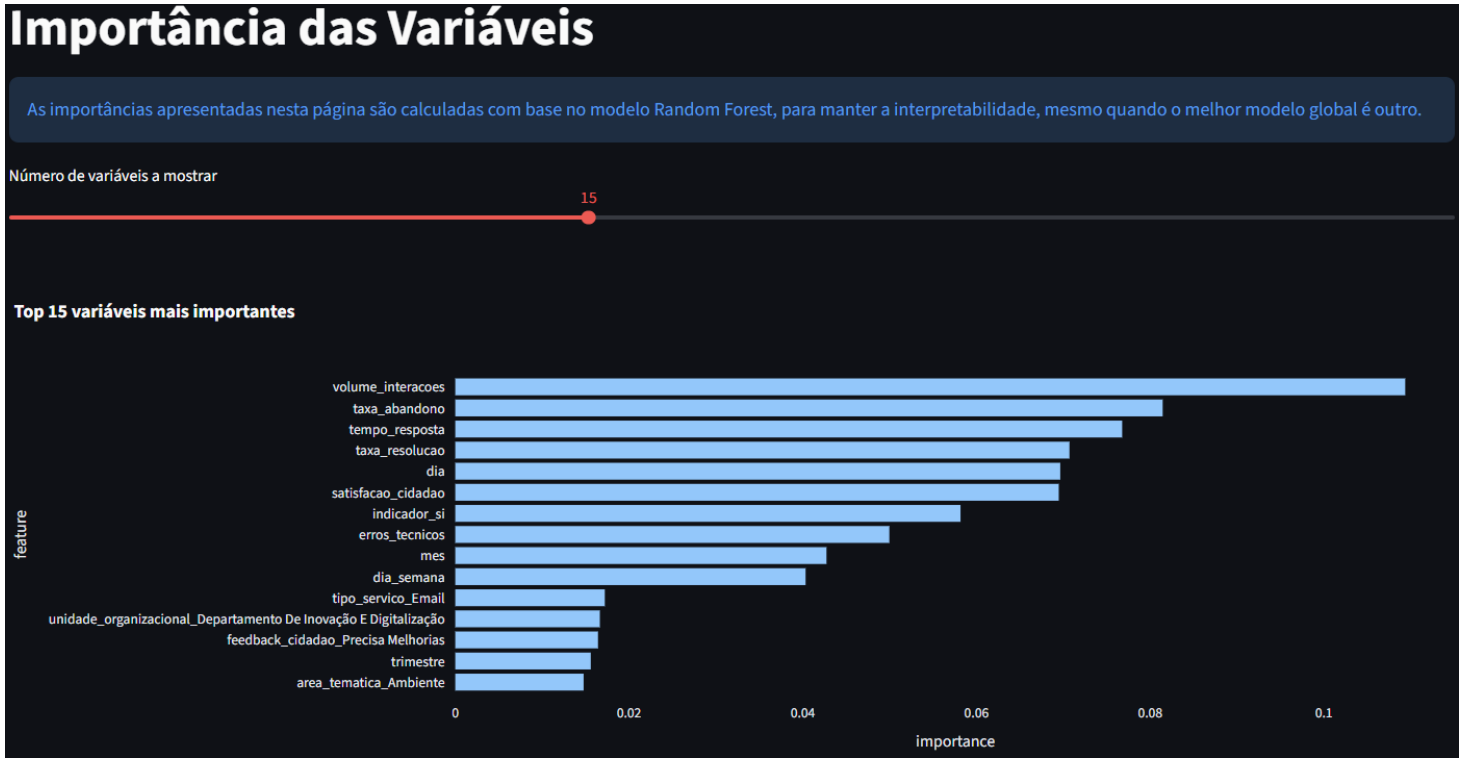
	row_id	model	actual	predicted	residual	abs_error
11	182	Dummy Regressor	99.99	74.6923	25.2977	25.2977
32	55	Dummy Regressor	50.11	74.6923	-24.5823	24.5823
12	165	Dummy Regressor	99.01	74.6923	24.3177	24.3177
2	30	Dummy Regressor	52.22	74.6923	-22.4723	22.4723
27	67	Dummy Regressor	95.02	74.6923	20.3277	20.3277
13	78	Dummy Regressor	55.79	74.6923	-18.9023	18.9023
7	170	Dummy Regressor	91.93	74.6923	17.2377	17.2377
17	152	Dummy Regressor	91.77	74.6923	17.0777	17.0777
26	84	Dummy Regressor	91.45	74.6923	16.7577	16.7577
37	137	Dummy Regressor	58.37	74.6923	-16.3223	16.3223

Leitura dos resíduos

- Resíduos próximos de zero indicam previsões mais ajustadas.
- Uma média dos resíduos próxima de zero sugere menor enviesamento médio.
- A dispersão dos resíduos ajuda a perceber se o erro é estável ou irregular.

O histograma dos resíduos mostra como os **erros distribuem-se em torno de zero, enquanto a tabela identifica os casos em que o erro absoluto foi mais elevado.** Em conjunto, estas duas componentes permitem perceber não só a forma global da distribuição do erro, mas também quais os exemplos concretos em que o modelo falhou mais.

Dashboard Interativo



Esta página apresenta as variáveis mais relevantes para o cálculo da importância, com base no modelo **Random Forest**. A utilização deste modelo permite manter uma leitura mais interpretável das features, mesmo quando o melhor modelo global do trabalho é outro.

Dashboard Interativo

Tabela completa

	feature_raw	feature	importance
0	num__volume_interacoes	volume_interacoes	0.1094
1	num__taxa_abandono	taxa_abandono	0.0814
2	num__tempo_resposta	tempo_resposta	0.0768
3	num__taxa_resolucao	taxa_resolucao	0.0707
4	num__dia	dia	0.0696
5	num__satisfacao_cidadao	satisfacao_cidadao	0.0695
6	num__indicador_si	indicador_si	0.0582
7	num__erros_tecnicos	erros_tecnicos	0.05
8	num__mes	mes	0.0427
9	num__dia_semana	dia_semana	0.0403

Interpretação

Esta página mostra quais as variáveis que mais influenciaram o modelo usado para calcular importância das variáveis.

Atenção:

- importância não significa causalidade;
- significa apenas que o modelo utilizou mais essas variáveis para construir a previsão;
- neste projeto, esta análise é feita com base no Random Forest.

A tabela **apresenta o ranking completo das variáveis e respetivos valores de importância,** permitindo uma leitura mais detalhada da contribuição de cada feature no modelo. A interpretação associada reforça que **importância não significa causalidade**, indicando apenas que determinadas variáveis foram mais utilizadas pelo modelo na construção da previsão.

Dashboard Interativo



A aplicação inclui um **formulário interativo que permite introduzir novos valores para as variáveis do problema, simulando a entrada de um novo registo.** O utilizador pode preencher campos numéricos, categóricos e temporais, reproduzindo as condições necessárias para gerar uma previsão do indicador KPI.

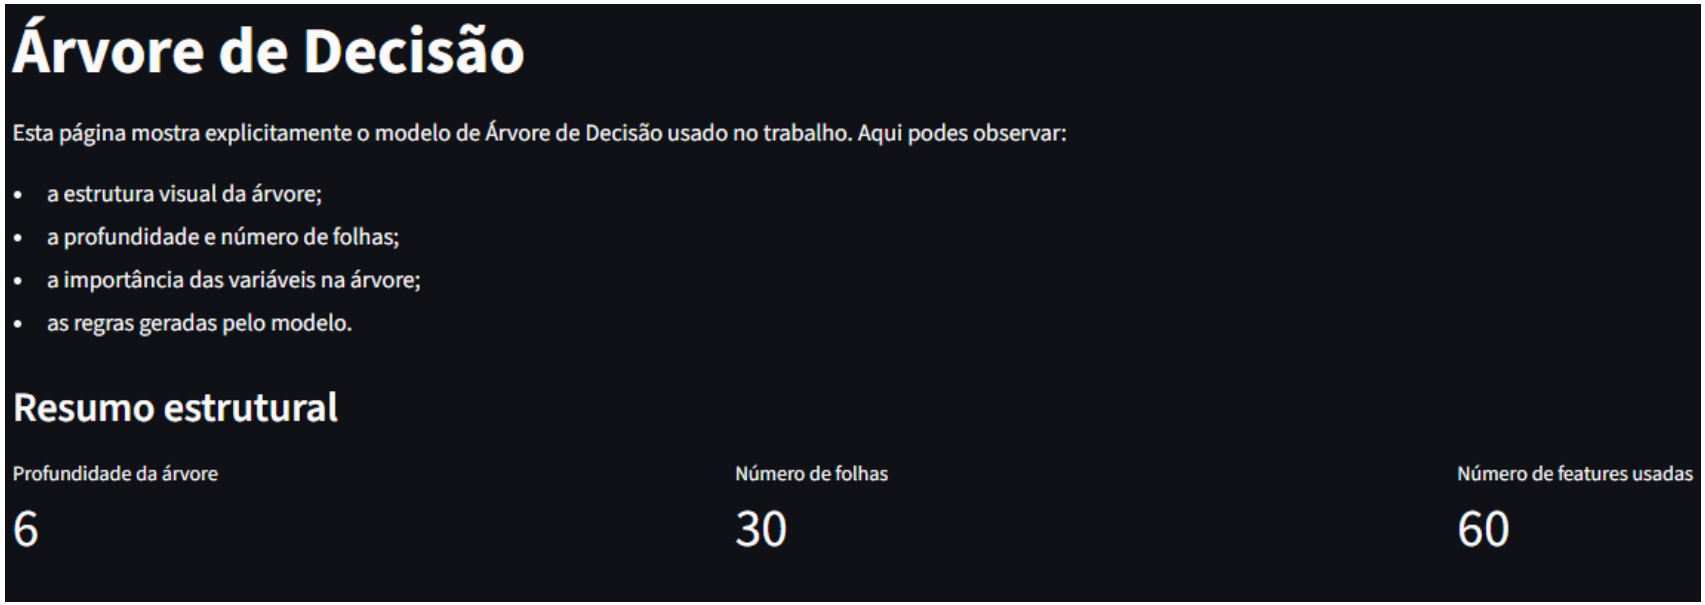
Dashboard Interativo



	data_registo	unidade_organizacional	tipo_servico	indicador_si	taxa_resolucao	tempo_resposta	satisfacao_cidadao	volume_interacoes	canal_utilizado	taxa_abandono	erros_tecnicos
0	2024-01-02	Departamento De Inovação E Digitalização	Atendimento Presencial	81.5833	82.9099	54	3.9855	251	Aplicacao_Movel	12.5555	7

Depois de submetidos os dados de entrada, a **aplicação apresenta automaticamente o valor previsto para o indicador KPI,** acompanhado de uma interpretação simples face ao histórico observado. Neste exemplo, a previsão obtida foi intermédia relativamente ao comportamento global do dataset.

Dashboard Interativo



Esta página apresenta uma **visão geral da Árvore de Decisão utilizada no trabalho,** destacando a sua profundidade, número de folhas e número de variáveis consideradas. Estes indicadores ajudam a perceber a complexidade do modelo e o nível de detalhe com que este divide os dados.

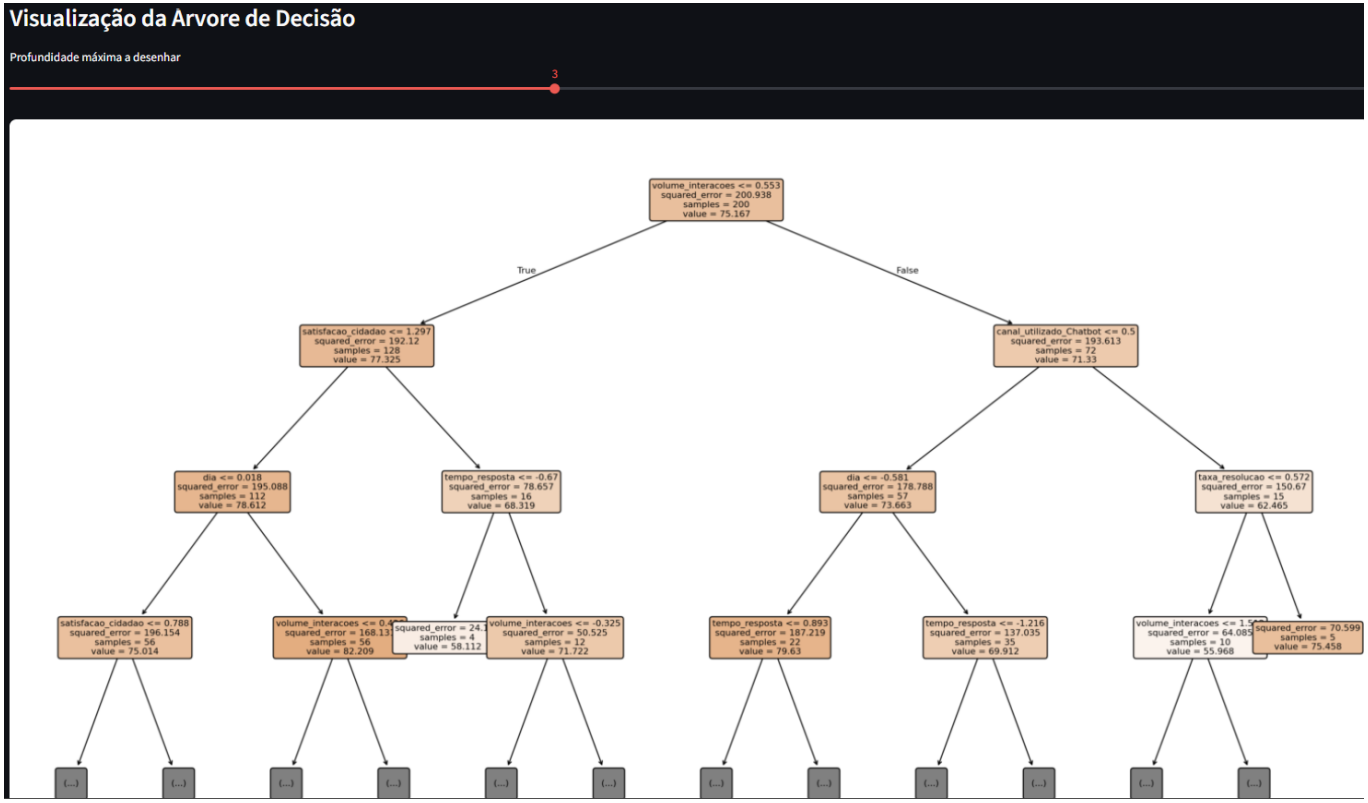
Dashboard Interativo



	feature	importance
4	volume_interacoes	0.2361
3	satisfacao_cidadao	0.1484
2	tempo_resposta	0.1172
9	dia	0.1055
5	taxa_abandono	0.0739
47	segmentacao_utilizador_Estudante	0.0694
1	taxa_resolucao	0.0593
28	canal_utilizado_Chatbot	0.0576
20	tipo_servico_Atendimento Presencial	0.0552
34	transparencia_Sim	0.036

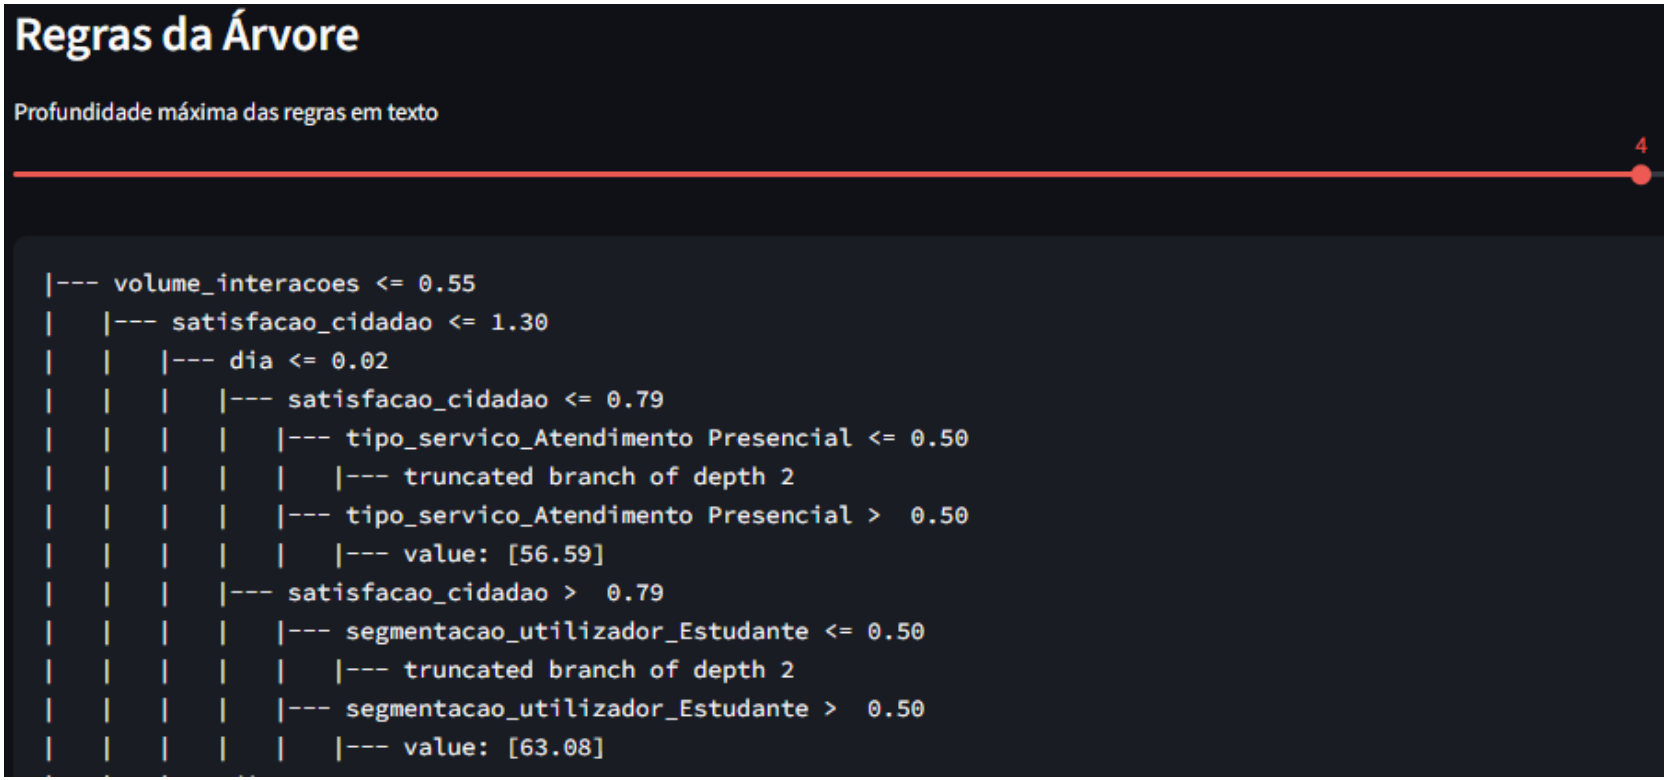
A tabela mostra as **variáveis com maior importância no modelo de Árvore de Decisão,** permitindo identificar quais os atributos que mais influenciaram a construção das divisões ao longo da árvore. Entre as variáveis mais relevantes destacam-se o **volume de interações**, a **satisfação do cidadão** e o **tempo de resposta**.

Dashboard Interativo



A representação gráfica da Árvore de Decisão permite observar diretamente a sequência de divisões efetuadas pelo modelo. Cada nó representa uma condição sobre uma variável, enquanto os ramos conduzem a diferentes subconjuntos de dados e, no final, a valores previstos do indicador KPI.

Dashboard Interativo



Para além da visualização gráfica, a **aplicação apresenta também as regras da Árvore de Decisão em formato textual.** Esta representação mostra de forma sequencial as condições aplicadas pelo modelo até chegar a um valor previsto.

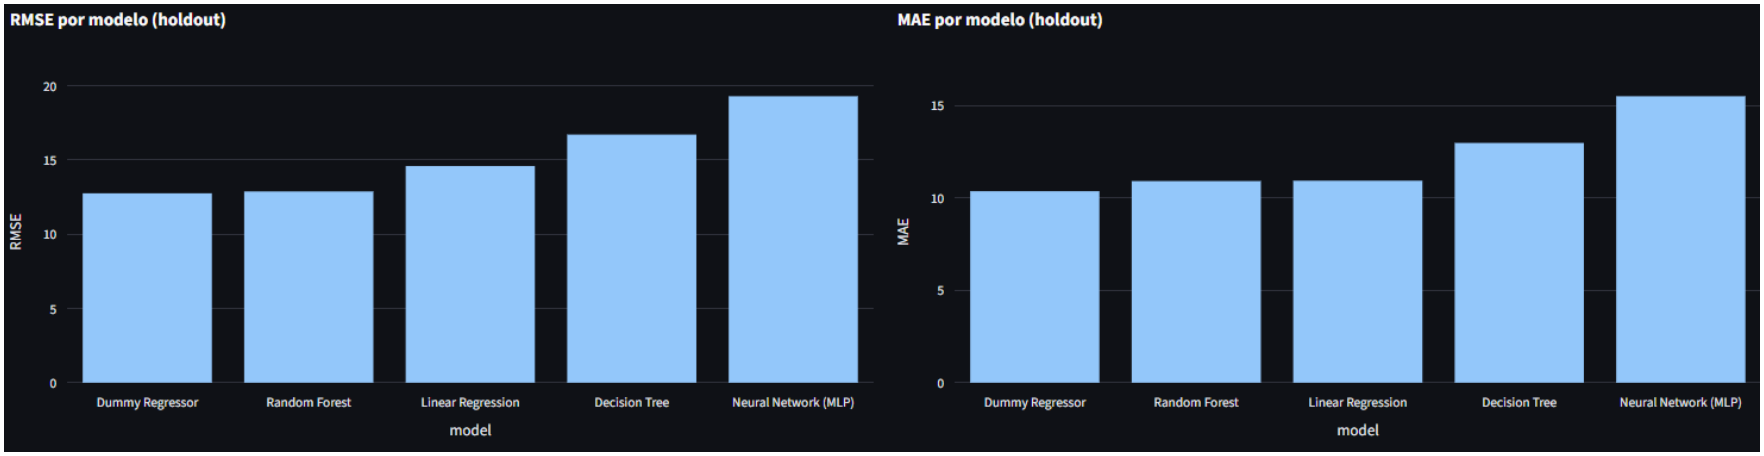
Dashboard Interativo

Interpretação

- A Árvore de Decisão divide os dados em regras sequenciais.
- Cada nó representa uma condição sobre uma variável.
- Cada folha representa um valor previsto para o indicador KPI.
- É um modelo mais interpretável do que Random Forest ou Rede Neuronal.
- No entanto, no teu trabalho, o Random Forest teve melhor desempenho global.

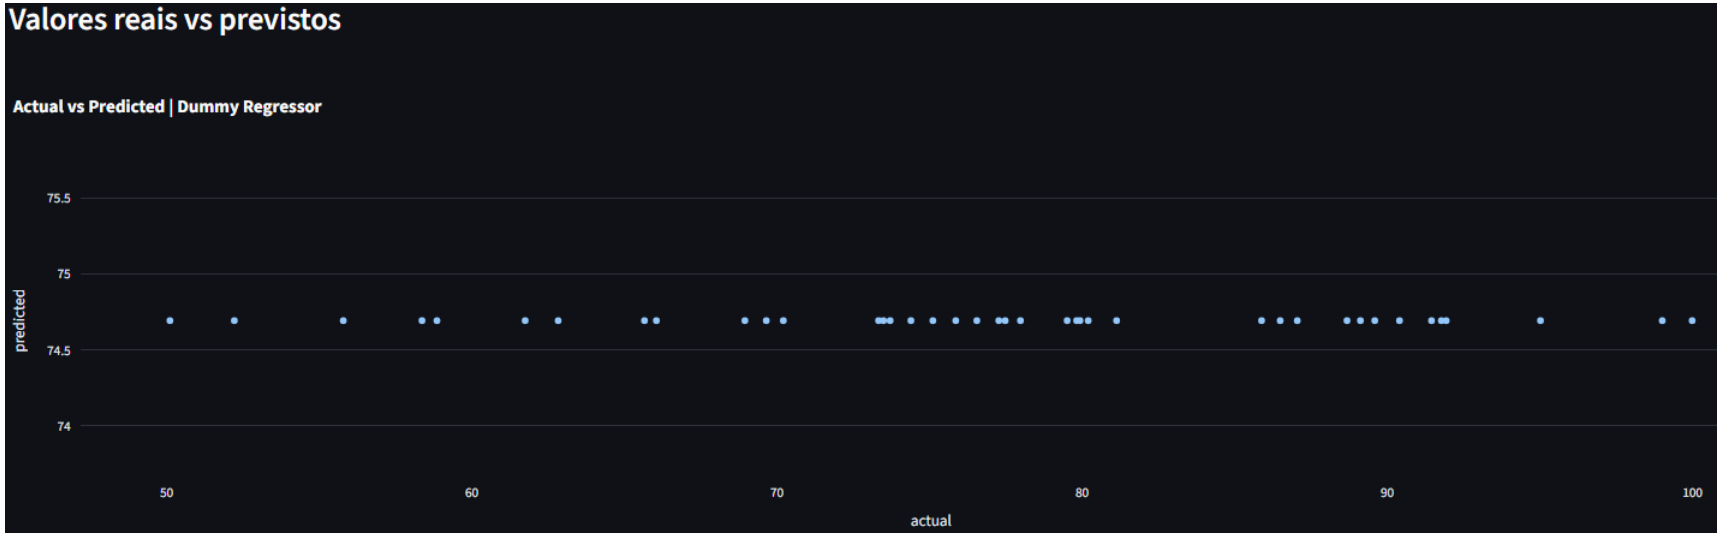
A Árvore de Decisão **divide os dados em regras sucessivas, baseadas em condições sobre as variáveis disponíveis.** Cada folha corresponde a um valor previsto para o KPI, tornando esta abordagem mais interpretável do que modelos como o Random Forest ou a Rede Neuronal.

Resultados e Discussão



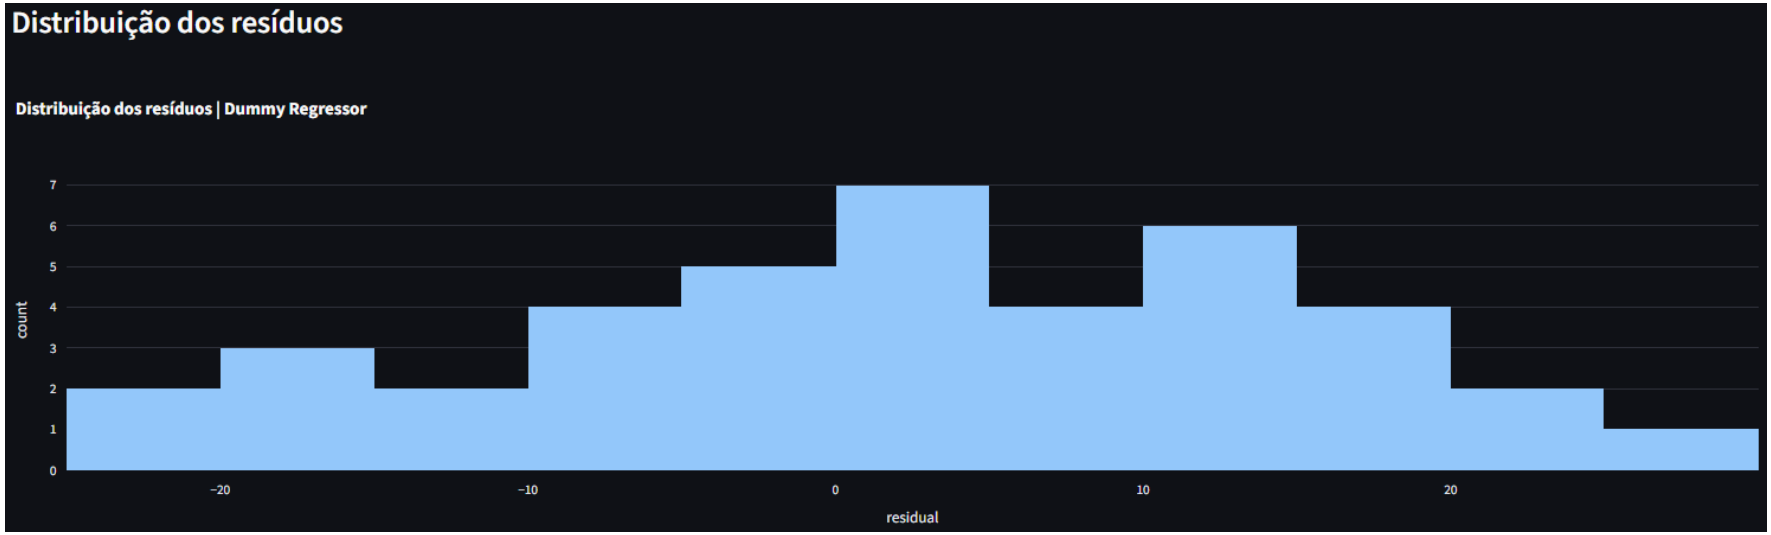
Os resultados obtidos mostram que o **Dummy Regressor apresenta os menores erros,** funcionando como baseline estatística no contexto do dataset analisado. Isto significa que, **segundo as métricas observadas, os restantes modelos não conseguiram melhorar esse valor.** Ainda assim, entre os modelos preditivos mais elaborados, o Random Forest destacou-se como a abordagem mais consistente, sendo por isso utilizado para a análise de importância das variáveis.

Resultados e Discussão



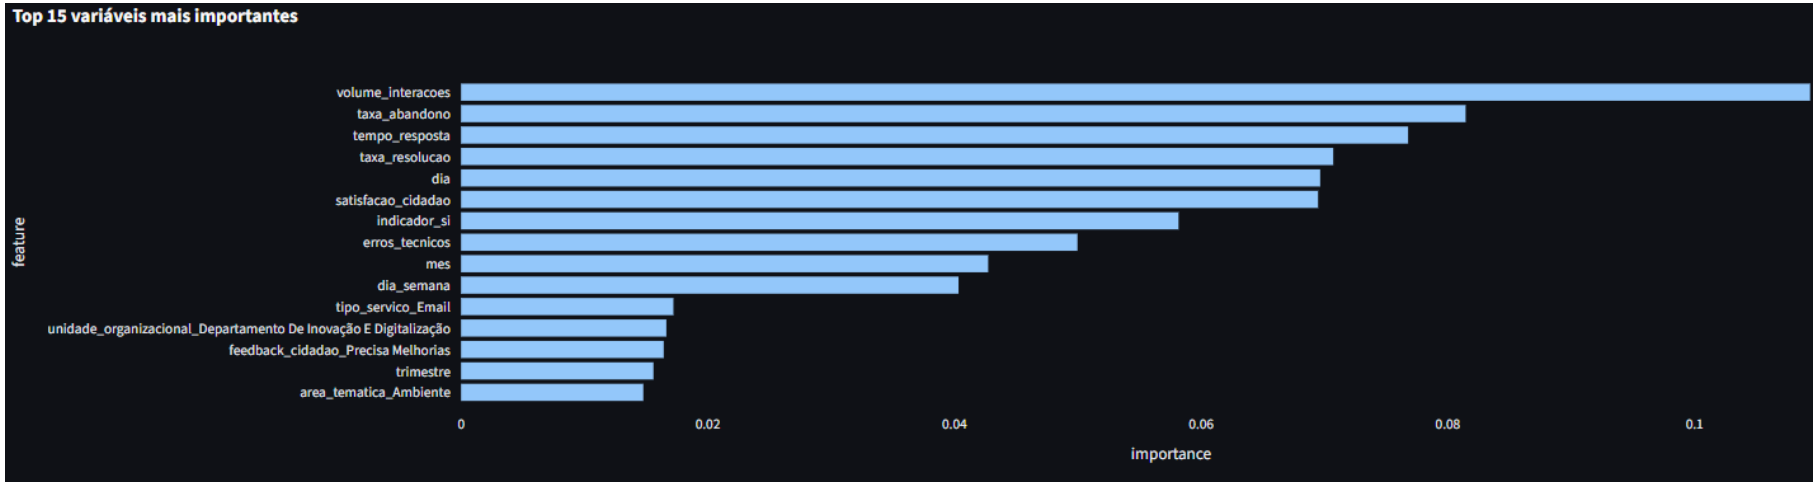
No caso do **Dummy Regressor, observa-se que todas as previsões são praticamente constantes, o que confirma que este modelo apenas devolve um valor médio de referência.** Esta visualização é importante porque mostra, de forma intuitiva, que a baseline não acompanha a variabilidade real dos dados.

Resultados e Discussão



O **histograma dos resíduos apresenta a distribuição dos erros em torno de zero.** Quando os resíduos estão muito dispersos, isso significa que o modelo apresenta dificuldade em ajustar-se aos valores reais observados. Neste caso, a **dispersão confirma que a baseline simples não consegue representar adequadamente a variabilidade do KPI.**

Resultados e Discussão



As variáveis com maior peso foram **volume de interações**, **taxa de abandono**, **tempo de resposta** e **taxa de resolução**.

Conclusão

O trabalho permitiu **desenvolver um fluxo completo de análise preditiva, desde a preparação dos dados até à comparação de modelos e visualização dos resultados.** O **Dummy Regressor apresentou os menores erros segundo as métricas obtidas,** enquanto o Random Forest se destacou como o modelo preditivo mais consistente entre as abordagens mais elaboradas. A utilização de MLflow e de um dashboard interativo em Streamlit reforçou a organização, a interpretação e a demonstração prática do projeto.

Referências

Dataset: Ficheiro disponibilizado pelo docente no Moodle.

o teu • de partida



www.ipvc.pt